

Chapitre 1 : État de l'art et positionnement scientifique

Le domaine juridique constitue, par la densité de sa terminologie, la rigueur de sa logique normative et la complexité de ses structures hiérarchiques, l'un des terrains les plus exigeants qui soient pour les systèmes d'intelligence artificielle. L'objectif de ce chapitre est de dresser un état de l'art structuré et critique des approches existantes, depuis les premières formalisations symboliques du raisonnement juridique jusqu'aux architectures hybrides les plus récentes combinant grands modèles de langage et représentation ontologique. Cette traversée de la littérature permettra d'identifier avec précision les lacunes qui persistent et de justifier, en regard de celles-ci, la pertinence et l'originalité de la contribution proposée dans ce mémoire : un système de question-réponse neuro-symbolique augmenté par graphe de connaissances, spécifiquement conçu pour répondre aux exigences du droit de l'environnement marin.

1.1 Intelligence artificielle appliquée au domaine juridique

L'idée d'automatiser le raisonnement juridique précède largement l'essor de l'informatique moderne et plonge ses racines dans les ambitions formalisatrices de la philosophie du droit du XIXe siècle. Sur le plan computationnel, les travaux fondateurs de McCarty (1977) avec TAXMAN qui est un système consacré à la modélisation du droit fiscal américain par représentation de structures de concepts et de relations causales et ceux d'Ashley et Rissland (1987) avec HYPO un système fondé sur le raisonnement analogique par cas juridiques, ont posé les jalons d'une informatique juridique formelle. Ces systèmes experts, architecturés autour de bases de règles du type « SI condition ALORS conséquence » et de moteurs d'inférence déductifs, reposaient sur le postulat que le droit pouvait être suffisamment formalisé pour être traité de manière algorithmique. Cette hypothèse s'est révélée simultanément fertile et trop optimiste.

Fertile, parce qu'elle a engendré un programme de recherche cohérent articulant logique déontique, représentation des connaissances et formalisation normative, programme qui demeure vivace aujourd'hui sous des formes renouvelées. Trop optimiste, parce que la richesse sémantique du texte juridique, ses ambiguïtés volontaires, ses renvois implicites, ses tensions internes entre normes concurrentes résiste à toute modélisation purement symbolique. La transition vers le machine learning dans les années 1990, puis vers le deep learning après 2010, a opéré une rupture paradigmatique : les systèmes apprenants ont

progressivement supplanté les approches symboliques pures, au prix d'une perte d'interprétabilité qui demeure aujourd'hui l'un des défis centraux du domaine. Des plateformes comme Westlaw Edge, LexisNexis Lexis+, Ross Intelligence (avant sa fermeture en 2021), Kira Systems ou Harvey AI témoignent de cette industrialisation rapide. Plus récemment, l'intégration de grands modèles de langage au cœur des outils juridiques professionnels a considérablement accéléré ce mouvement : les expériences de déploiement de GPT-4 chez des cabinets d'avocats, relatées dans la presse spécialisée dès 2023, illustrent à la fois les gains de productivité promis et les risques de défaillance documentés (hallucinations, citations fictives de jurisprudences, erreurs de qualification normative).

Sur le plan académique, trois tensions fondamentales structurent les débats contemporains. La première est celle de la transparence algorithmique face à l'exigence constitutionnelle de motivation des décisions judiciaires : dans les systèmes de droit continental comme dans ceux de common law, toute décision juridique doit pouvoir être rationnellement justifiée, ce qu'un modèle boîte noire est par nature incapable de garantir. La deuxième tension concerne la fiabilité des prédictions dans des contextes à fort enjeu pénal, constitutionnel, environnemental, où les conséquences d'une erreur sont potentiellement irréversibles. La troisième touche à l'équité algorithmique : les corpus d'entraînement, reflétant les biais historiques de la pratique judiciaire, peuvent reproduire et amplifier des discriminations systémiques, posant de graves problèmes éthiques et juridiques. C'est la persistance de ces tensions irrésolues qui justifie la recherche d'architectures hybrides, capables de combiner la puissance expressive des réseaux de neurones avec la rigueur démonstrative des systèmes symboliques.

1.2 Le traitement automatique du langage juridique

Le langage juridique présente une configuration linguistique singulière qui le distingue profondément du langage ordinaire et rend son traitement automatique particulièrement exigeant. Sa densité terminologique se caractérise par la coexistence, au sein d'un même corpus, de notions hautement spécialisées à forte stabilité sémantique telles que « force majeure », « préjudice certain » ou « zone économique exclusive » et de termes dont la portée varie selon le domaine juridique considéré, le système normatif de référence ou encore le contexte historique de production. Dans le champ spécifique du droit de l'environnement marin, cette complexité est renforcée par la superposition de plusieurs strates discursives : vocabulaire du droit international, concepts issus des sciences océaniques, catégories propres

au droit de l'environnement, ainsi que notions techniques relatives à la régulation des espaces maritimes. À cette hétérogénéité lexicale s'ajoute une ambiguïté normative structurelle. Celle-ci ne relève pas uniquement d'imprécisions rédactionnelles, mais constitue souvent un choix délibéré du législateur, visant à préserver une marge d'adaptation interprétative face à des contextes évolutifs. Ainsi, des formulations volontairement ouvertes telles que l'obligation de prendre « toutes les mesures nécessaires » pour prévenir la pollution marine admettent des interprétations variables selon les cadres d'application et les configurations factuelles. Les approches fondées sur des représentations distributionnelles, bien qu'efficaces pour capter des régularités statistiques, se révèlent limitées dès lors qu'il s'agit de préserver ces nuances interprétatives, dans la mesure où elles tendent à homogénéiser des distinctions sémantiques pourtant essentielles à la lecture juridique.

Dans ce contexte, les tâches de traitement automatique du langage juridique reposent sur un ensemble de mécanismes complémentaires visant à structurer et organiser l'information normative. Parmi celles-ci, la reconnaissance d'entités nommées (Named Entity Recognition, NER) occupe une fonction centrale. Elle ne se limite pas à l'identification des références législatives ou des unités textuelles formelles, mais permet également l'extraction systématique des entités juridiques structurantes, des acteurs institutionnels ou étatiques, des espaces géographiques pertinents notamment les différentes zones maritimes ainsi que des objets normatifs et environnementaux mobilisés dans les raisonnements juridiques. Le NER constitue ainsi une étape fondamentale de transformation des textes juridiques non structurés en représentations exploitables, en rendant explicites les éléments constitutifs du tissu normatif.

Toutefois, cette opération d'extraction demeure intrinsèquement limitée : si elle permet d'identifier les entités pertinentes, elle ne suffit pas à restituer les relations complexes qui les unissent. C'est pourquoi elle s'inscrit généralement dans un ensemble plus large de tâches comprenant l'extraction de relations normatives (telles que l'abrogation, la modification ou le renvoi), la classification des énoncés selon leur modalité déontique (obligation, interdiction, permission), ainsi que la résolution de coréférences dans des documents longs et fortement structurés. L'ensemble de ces opérations vise à reconstruire, de manière algorithmique, une architecture cohérente du discours juridique.

Les recherches récentes en traitement automatique du langage juridique ont donné lieu à plusieurs cadres d'évaluation permettant de mesurer les performances des modèles sur ces différentes dimensions. Ces dispositifs mettent en évidence une tendance récurrente : les

modèles génériques atteignent rapidement leurs limites dès lors que la précision conceptuelle et la cohérence normative deviennent déterminantes, notamment dans des tâches impliquant des dépendances sémantiques longues ou des structures hiérarchiques complexes. Cette difficulté est accentuée dans les corpus relatifs au droit de l'environnement marin, où la diversité des entités, la granularité des espaces juridiques et la pluralité des registres normatifs exigent une capacité de représentation particulièrement fine.

Dans ce cadre, les approches actuelles révèlent à la fois des progrès significatifs en matière de structuration automatique du langage juridique et des limites persistantes dès qu'il s'agit de reproduire la profondeur interprétative propre au raisonnement juridique. Le NER, bien qu'essentiel, apparaît ainsi comme une composante nécessaire mais non suffisante d'un système de compréhension juridique automatisée, dont la complexité réside précisément dans l'articulation entre extraction d'information, structuration relationnelle et interprétation normative.

1.3 Les grands modèles de langage (LLMs)

L'architecture Transformer, introduite par Vaswani et al. (2017), a constitué le tournant décisif de l'histoire récente du traitement automatique du langage. En permettant de modéliser les dépendances contextuelles à longue portée dans les séquences textuelles grâce au mécanisme d'attention multi-têtes, cette architecture a surmonté les limitations inhérentes aux réseaux récurrents qui dominaient jusqu'alors. Les modèles qui en sont issus la famille GPT d'OpenAI, LLaMA de Meta, Mistral AI, Claude d'Anthropic affichent des capacités de génération et de compréhension que l'on n'aurait pas imaginées possibles il y a une décennie.

Plusieurs travaux ont cherché à tirer parti de ces architectures pour le droit en recourant au fine-tuning sur des corpus spécialisés. LEGAL-BERT (Chalkidis et al., 2020), pré-entraîné sur la législation de l'Union européenne, les arrêts de la Cour européenne des droits de l'homme et des corpus contractuels, améliore significativement les performances sur les tâches NLP juridiques standard. Plus récemment, SaulLM-7B puis SaulLM-54B (Colombo et al., 2024) ont poussé cette logique plus loin, en combinant pré-entraînement sur un corpus juridique massif de plusieurs centaines de milliards de tokens avec une instruction fine-tuning spécialisée. Ces modèles établissent des performances de référence sur plusieurs benchmarks juridiques, démontrant que la spécialisation par domaine apporte des gains substantiels par rapport aux modèles généraux de taille comparable. En Chine, LawBench (Fei et al., 2023) a fourni un cadre d'évaluation analogue pour le droit chinois, révélant des dynamiques

similaires. Pourtant, ces avancées ne résolvent pas les limitations structurelles qui rendent ces modèles fondamentalement inadaptés à une utilisation autonome en contexte normatif. La première et peut-être la plus grave est le phénomène des hallucinations c'est à dire la génération d'informations factuellement incorrectes mais stylistiquement plausibles. En contexte juridique, ce risque prend une dimension particulièrement sérieuse : un modèle peut citer des textes législatifs inexistants, attribuer des positions jurisprudentielles erronées à des juridictions, ou produire des raisonnements légalement invalides présentés avec toute l'autorité formelle d'un expert. La manière dont ces erreurs s'habillent du style de la rigueur juridique les rend d'autant plus dangereuses qu'elles sont difficiles à détecter sans une vérification indépendante systématique. Le manque de traçabilité aggrave ce problème. Il est impossible, avec un LLM standard, de retracer le cheminement par lequel une réponse a été construite ni d'identifier les sources qui l'ont alimentée, une incompatibilité fondamentale avec les exigences de motivation propres au raisonnement juridique, qui veut que toute affirmation normative soit rattachable à une source textuelle précise et hiérarchiquement localisable.

L'absence de raisonnement formel constitue sans doute la limitation la plus profonde. Au sens logique et déontique du terme, le raisonnement juridique exige d'appliquer des règles normatives de manière déductive, de détecter des contradictions entre normes hiérarchisées et de propager les effets d'une disposition sur les normes qu'elle conditionne. Ces opérations sont au cœur de la pratique juridique, mais elles sont totalement étrangères aux LLMs, dont le fonctionnement relève de la prédiction probabiliste de tokens et non de l'inférence formelle. La recherche sur l'application du chain-of-thought prompting (Wei et al., 2022) au droit a montré que ces techniques amélioraient la cohérence apparente des raisonnements produits, sans pour autant garantir leur validité normative, une distinction que le juriste perçoit immédiatement mais que le non-spécialiste risque de manquer.

1.4 Les systèmes de question-réponse juridiques : taxonomie et benchmarks

Les systèmes de question-réponse (Q/R) appliqués au droit se classent selon une taxonomie tripartite qui reflète une progression dans l'autonomie de la génération et le rapport entretenu avec les sources documentaires. Les architectures extractives identifient, dans un corpus documentaire préalablement indexé, le passage textuel le plus susceptible de constituer une réponse à la question posée, sans reformulation ni synthèse. Elles offrent une haute traçabilité où chaque réponse est directement ancrée dans une source vérifiable, mais souffrent d'une

rigidité structurelle face aux questions requérant une synthèse à partir de sources multiples, une inférence à partir de règles implicites ou une reformulation adaptée au niveau de l'interlocuteur.

Les architectures génératives produisent une réponse formulée en langage naturel à partir des connaissances encodées dans les paramètres du modèle, sans nécessairement s'appuyer sur des sources externes identifiables. Elles sont fluides, adaptatives et capables d'une certaine forme de raisonnement apparent, mais demeurent exposées aux hallucinations mentionnées précédemment et ne permettent pas la vérification post-hoc de leurs assertions. Les architectures hybrides, combinant retrieval et génération, constituent l'état de l'art actuel et font l'objet de la section 1.5.

Parmi les benchmarks existants, JEC-QA (Zhong et al., 2020) évalue la compréhension du droit chinois à travers des questions à choix multiples tirées d'examens du barreau. CaseHOLD (Zheng et al., 2021) porte sur la prédiction de l'application jurisprudentielle américaine. COLIEE confronte annuellement les systèmes à des tâches de recherche d'information légale et d'entailment dans le droit japonais et canadien. LegalBench (Guha et al., 2023), le plus ambitieux des benchmarks récents, décompose le raisonnement juridique en cinq grandes compétences : identification des normes applicables, application des faits à la règle, interprétation, conclusion, argumentation rhétorique et révèle que même les modèles les plus performants peinent sur les tâches d'application normative complexe, précisément celles qui caractérisent le raisonnement juridique expert.

À ce jour, aucun benchmark standardisé n'est spécifiquement consacré au droit de l'environnement marin. Cette absence constitue une limite importante dans la littérature actuelle, mais représente également une opportunité scientifique significative.

1.5 Le RAG classique : principes, apports et limites pour le droit

Le paradigme de génération augmentée par récupération d'information (Retrieval-Augmented Generation ou RAG), formalisé par Lewis et al. (2020) puis enrichi par de nombreux travaux ultérieurs, s'est imposé comme une réponse aux principales limites des grands modèles de langage, notamment l'obsolescence des connaissances internes et l'absence de traçabilité des réponses générées. Son principe consiste à compléter les capacités génératives d'un modèle par l'accès dynamique à des sources documentaires externes, mobilisées au moment de l'inférence. Le modèle ne se fonde donc plus uniquement sur les

connaissances apprises durant son entraînement, mais sur des informations explicitement récupérées à partir d'un corpus de référence.

Dans sa forme classique, un système RAG repose sur une chaîne de traitement composée de plusieurs étapes successives. La première consiste à segmenter le corpus documentaire en unités textuelles exploitables, communément appelées *chunks*. Ces segments sont ensuite transformés en représentations vectorielles grâce à des modèles d'embedding capables de capturer leur contenu sémantique. Les vecteurs produits sont stockés dans une base vectorielle spécialisée, telle que FAISS, Chroma ou Weaviate, afin de permettre une recherche rapide. Lorsqu'une requête utilisateur est formulée, celle-ci est à son tour vectorisée puis comparée aux représentations du corpus afin d'identifier les passages les plus pertinents. Les documents récupérés sont enfin injectés dans le prompt du modèle génératif, qui produit la réponse finale en s'appuyant sur ce contexte externe.

La performance d'un système RAG dépend toutefois fortement de la qualité de la segmentation initiale du corpus. Le *chunking* constitue une étape particulièrement déterminante, car il conditionne directement la pertinence des documents récupérés. Des segments trop courts risquent de fragmenter l'information et de supprimer des éléments contextuels essentiels, tandis que des segments trop longs peuvent introduire du bruit informationnel et réduire la précision du mécanisme de recherche. Dans les domaines spécialisés, et plus particulièrement dans le domaine juridique, cette problématique devient encore plus critique. Une disposition normative tire souvent son sens de son articulation avec d'autres articles, définitions, annexes ou exceptions. Une segmentation purement fondée sur un nombre fixe de tokens peut ainsi rompre la continuité logique d'un texte juridique et altérer la qualité du raisonnement ultérieur. La conception d'un bon système RAG repose donc en grande partie sur une stratégie de segmentation adaptée à la structure documentaire du corpus. Afin de surmonter certaines limites du pipeline classique, plusieurs variantes ont été proposées dans la littérature récente. Les approches intégrant une étape de re-ranking ajoutent un mécanisme de réévaluation des documents récupérés afin d'améliorer leur classement selon des critères de pertinence plus fins que la simple similarité vectorielle. Des méthodes comme Cross-Encoder re-ranking ou ColBERT s'inscrivent dans cette logique. D'autres travaux, comme HyDE (Hypothetical Document Embeddings) proposé par Gao et al. (2022), génèrent d'abord un document hypothétique répondant à la question avant d'effectuer la recherche documentaire, ce qui améliore la récupération pour les requêtes complexes ou abstraites. Plus récemment, RAPTOR (Sarathi et al., 2024) propose une organisation

hiérarchique du corpus fondée sur des résumés récurifs, permettant un mécanisme de récupération multi-niveaux plus adapté aux documents volumineux et structurés.

Malgré ces avancées, l'application du RAG au domaine juridique demeure confrontée à des limites importantes liées à la nature même des textes normatifs. Les mécanismes traditionnels de recherche sémantique identifient principalement des proximités lexicales ou contextuelles, sans toujours prendre en compte les relations logiques qui structurent l'ordre juridique, telles que la hiérarchie des normes, les mécanismes de dérogation, les renvois explicites ou les conditions d'application particulières. En conséquence, un système RAG classique peut récupérer une règle générale pertinente tout en ignorant une disposition spéciale qui en restreint la portée, produisant ainsi une réponse cohérente sur le plan linguistique mais juridiquement inexacte.

Dans des domaines hautement spécialisés comme le droit de l'environnement marin, ces limites deviennent encore plus visibles en raison de la multiplicité des instruments juridiques mobilisés et de l'interdépendance constante entre normes internationales, régionales et sectorielles. Cela souligne la nécessité de concevoir des architectures RAG capables d'intégrer non seulement la recherche documentaire, mais également la structure normative propre au raisonnement juridique.

1.6 Ontologies et représentation des connaissances juridiques

Les ontologies constituent l'un des principaux formalismes de représentation des connaissances en intelligence artificielle lorsqu'il s'agit de modéliser explicitement la structure conceptuelle d'un domaine complexe. Selon la définition proposée par Guarino et al. (2009), une ontologie correspond à une spécification explicite d'une conceptualisation partagée. Elle permet de formaliser les concepts d'un domaine, les relations qui les relient ainsi que les contraintes qui gouvernent leur utilisation. L'objectif n'est pas uniquement de stocker de l'information, mais de rendre cette connaissance interprétable par des machines et exploitable dans des mécanismes de raisonnement automatique.

Sur le plan technique, les ontologies s'appuient généralement sur les standards du Web sémantique. RDF permet de représenter les connaissances sous forme de triplets, RDFS introduit des hiérarchies entre classes et propriétés, tandis qu'OWL offre une expressivité logique plus avancée en permettant de définir des restrictions, des axiomes et des règles d'inférence. Ces technologies ont largement contribué au développement de systèmes

capables de manipuler des connaissances structurées dans des domaines où la précision conceptuelle est essentielle.

Le domaine juridique a donné lieu à plusieurs initiatives majeures en matière de modélisation ontologique. Parmi elles, LKIF-Core (Legal Knowledge Interchange Format Core) développé par Hoekstra et al. (2007) demeure l'une des références les plus importantes. Cette ontologie propose une structuration des concepts juridiques fondamentaux tels que les normes, les obligations, les droits, les agents juridiques, les actions et les processus normatifs. Son architecture modulaire en fait un cadre particulièrement adapté aux systèmes de raisonnement juridique.

D'autres travaux ont enrichi cette dynamique. LegalRuleML a été conçu pour représenter formellement les règles juridiques et leurs modalités déontiques, notamment l'obligation, l'interdiction et la permission. Ces initiatives ont permis d'améliorer la représentation formelle des connaissances juridiques, tout en montrant que les besoins varient selon ce que l'on recherche soit le raisonnement normatif ou l'organisation documentaire.

La construction automatique d'ontologies à partir de corpus textuels constitue désormais un axe de recherche à part entière. Feng et al. (2024) proposent une approche fondée sur la génération de questions de compétence (Competency Questions) par un LLM à partir d'un corpus non structuré. Ces questions permettent de délimiter le périmètre de connaissance du domaine, d'en extraire les relations pertinentes et de les aligner sur le schéma de Wikidata. Le graphe de connaissances résultant, formellement ancré dans cette ontologie, est interopérable avec Wikidata et atteint des performances compétitives sur les benchmarks Wiki-NRE, SciERC et WebNLG. Cette approche illustre comment les LLMs peuvent être mis au service de la construction ontologique plutôt qu'utilisés de manière autonome, exploitant leur capacité à mémoriser des schémas relationnels appris lors du pré-entraînement.

Dans une direction complémentaire, Langer et al. (2024) ont développé CEAR, un graphe de connaissances d'entités et de rôles chimiques construit à partir de 8 000 articles de ChemRxiv en combinant un modèle Electra fine-tuné pour la reconnaissance d'entités nommées et un modèle LLAMA-2 pour la validation des relations identifiées. L'ancrage sur l'ontologie ChEBI assure la cohérence et l'interopérabilité du graphe produit. Cette architecture à deux LLMs l'un pour l'identification, l'autre pour la vérification préfigure les pipelines de validation que l'on retrouvera dans les architectures neuro-symboliques plus récentes. Bien

que le domaine d'application soit chimique, la méthode est directement transposable à la construction automatique de bases de connaissances juridiques à partir de corpus normatifs. Malgré ces avancées, aucune ontologie spécifiquement dédiée au droit de l'environnement marin n'a été identifiée à ce jour. Les ontologies juridiques existantes, bien qu'utiles pour modéliser des concepts normatifs généraux, ne permettent pas de représenter avec précision les concepts spécifiques à ce domaine.

1.7 Les graphes de connaissances : structure, expressivité et applications normatives

Les graphes de connaissances (*Knowledge Graphs*) constituent un mécanisme de représentation structuré permettant de modéliser des entités et les relations qui les relient sous forme de triplets tels que (*sujet, prédicat, objet*) ou de graphes composés de nœuds et de relations typées. Cette représentation permet de transformer des informations textuelles non structurées en connaissances explicites, interconnectées et directement exploitables par des systèmes de raisonnement automatisé. Ces derniers sont implémentés par des systèmes de gestion distincts : les RDF Stores (Blazegraph, Apache Jena, Stardog) permettent d'interroger les données via SPARQL et d'appliquer des règles d'inférence OWL ; Neo4j, représentant dominant du Property Graph, offre le langage de requête Cypher et des algorithmes natifs de parcours de graphe.

Dans le domaine juridique, cette approche présente un intérêt particulier car elle permet de dépasser les limites des représentations purement textuelles ou vectorielles en rendant explicites les relations normatives présentes dans les documents juridiques. À partir d'un corpus composé de conventions internationales relatives au droit de l'environnement marin, un graphe de connaissances peut par exemple représenter les différents acteurs concernés, les zones maritimes mentionnées, les activités réglementées, les ressources concernées ainsi que les obligations, interdictions, autorisations ou exceptions prévues par les textes.

Ainsi, une disposition interdisant le rejet de substances polluantes dans une zone maritime spécifique peut être représentée de manière structurée en reliant l'acteur concerné, l'activité interdite, la zone concernée et la norme juridique qui fonde cette interdiction. De la même manière, les relations entre différentes conventions internationales peuvent être explicitement modélisées afin d'identifier les complémentarités, les renvois ou les chevauchements normatifs existants.

Cette capacité de structuration est particulièrement pertinente dans le cadre du droit de l'environnement marin, où l'information juridique est dispersée dans plusieurs conventions

internationales et souvent exprimée dans un langage complexe. En transformant ces textes en relations explicites, les graphes de connaissances facilitent l'identification rapide des règles applicables et améliorent la qualité du raisonnement juridique automatisé.

Les travaux récents, notamment celui de Khorshidi et al. (2025) avec le système ODKE+, montrent également que les grands modèles de langage peuvent être mobilisés pour automatiser l'extraction de faits destinés à alimenter ces graphes tout en intégrant des mécanismes de validation pour limiter les erreurs. Bien que développé dans un contexte différent, ce type d'approche confirme l'intérêt de combiner extraction automatique et structuration relationnelle.

1.8 GraphRAG et retrieval enrichi par les graphes : état de l'art

Le GraphRAG, formalisé par Edge et al. (2024) chez Microsoft Research, constitue une évolution majeure du paradigme RAG en substituant ou en complétant la recherche vectorielle par une traversée de graphe de connaissances. Lors du retrieval, au lieu de se limiter aux chunks les plus similaires lexicalement à la requête, le système navigue dans le graphe à partir des entités identifiées dans la question, en explorant les nœuds voisins, les chemins et les sous-graphes pertinents. Le contexte injecté dans le LLM inclut ainsi des relations structurelles que la similarité vectorielle seule ne peut révéler.

Comparé au RAG vectoriel pur, le GraphRAG présente des forces notables : une meilleure cohérence sémantique du contexte récupéré, une capacité à traverser des chaînes de raisonnement si A implique B et B interdit C, alors A interdit C, et une résistance à la variation terminologique grâce à l'ancrage sur des entités nommées plutôt que sur des représentations vectorielles continues. Ces propriétés le rendent a priori particulièrement adapté au domaine juridique, où les raisonnements multi-sauts sur des normes hiérarchisées sont la règle.

OG-RAG (Sharma et al., 2025) pousse cette logique plus loin en représentant le corpus sous forme d'hypergraphes ontologiques plutôt que de simples graphes d'entités. Un hypergraphe généralise la notion de graphe en autorisant les hyperarêtes à connecter un nombre arbitraire de nœuds, ce qui permet de capturer des relations factuelles complexes impliquant plusieurs entités simultanément. L'auteur démontre que cette représentation améliore non seulement le rappel factuel mais aussi la capacité de raisonnement déductif : OG-RAG permet à un LLM d'inférer des conclusions non directement présentes dans les documents, à condition que les faits nécessaires à la déduction soient représentés dans l'hypergraphe (Sharma et al., 2025).

Cette propriété est d'une importance capitale pour le droit, où de nombreuses conclusions normatives résultent de la combinaison de plusieurs dispositions disparates.

Les limites de ces architectures résident dans la dépendance à la qualité du graphe sous-jacent, le coût de sa construction et de sa maintenance, et la complexité accrue des requêtes multi-sauts dans des graphes de grande échelle. Plus fondamentalement, ni le GraphRAG ni OG-RAG ne garantissent la conformité normative des réponses générées : ils structurent le retrieval, mais ne vérifient pas formellement que les assertions produites par le LLM sont cohérentes avec l'ensemble des normes applicables.

1.9 Le raisonnement neuro-symbolique

Le raisonnement neuro-symbolique désigne un paradigme hybride visant à combiner les capacités de généralisation et de traitement du langage naturel des réseaux de neurones profonds avec la rigueur déductive et l'interprétabilité des systèmes symboliques. Cette combinaison répond directement aux faiblesses complémentaires des deux paradigmes : le sous-système symbolique corrige la tendance aux hallucinations du LLM en vérifiant la conformité des assertions générées contre une base formelle de connaissances ; le sous-système neuronal permet de traiter la variabilité linguistique et l'ambiguïté que les systèmes purement symboliques ne peuvent gérer.

Plusieurs approches d'intégration ont été proposées. La génération contrainte (Constrained Decoding) oriente le processus de décodage du LLM pour que les tokens générés respectent une grammaire formelle ou des règles logiques prédéfinies (Scholak et al., 2021). L'approche NeSy de De Raedt et al. incorpore des contraintes probabilistes-logiques dans l'apprentissage lui-même. LLM+SPARQL permet au modèle de formuler des requêtes vers une base de connaissances formelle pour y vérifier ses assertions avant de les inclure dans la réponse finale. Ces approches trouvent une application naturelle en droit pour la vérification de cohérence normative en temps réel.

Le système SymRAG, proposé par Hakim et al. (2025), offre une illustration concrète de la combinaison neuro-symbolique appliquée au paradigme RAG. SymRAG introduit un routage adaptatif des requêtes : selon une évaluation en temps réel de la complexité de la question et de l'état des ressources système, la requête est dirigée vers un chemin symbolique (traversée de graphe, règles déductives), un chemin neuronal (retrieval dense suivi de génération) ou un chemin hybride combinant les deux. Les résultats expérimentaux sur HotpotQA et DROP démontrent que ce routage adaptatif atteint un taux d'exacte

correspondance de 97,6 à 100 %, tout en maintenant une utilisation CPU en deçà de 6,2 % un avantage décisif pour un déploiement en production (Hakim et al., 2025). L'expérience la plus révélatrice est l'ablation : désactiver le routage adaptatif augmente le temps de traitement de 169 à 1 151 % selon le modèle, ce qui illustre l'importance critique de l'adaptation dynamique pour des architectures hybrides à grande échelle.

L'analyse des chemins effectivement empruntés par SymRAG révèle un résultat contre-intuitif : les LLMs modernes n'empruntent quasiment jamais le chemin purement symbolique (0,1 % pour le jeu de données DROP, 0 % pour HotpotQA), préférant les chemins hybrides ou neuronaux. Hakim et al. (2025) interprètent ce comportement comme la preuve que les LLMs ont internalisé une part substantielle du raisonnement symbolique lors de leur pré-entraînement, ce qui suggère que leur intégration dans des architectures hybrides doit tenir compte de cette compétence latente plutôt que de la remplacer systématiquement par des modules symboliques explicites.

1.10 Travaux connexes et systèmes apparentés

Au-delà des architectures et paradigmes généraux analysés dans les sections précédentes, plusieurs systèmes se rapprochent de la démarche poursuivie dans ce mémoire, en ce qu'ils cherchent à articuler traitement du langage naturel, représentation structurée des connaissances juridiques et vérification de la conformité normative.

Dans le domaine des systèmes hybrides, ChatLaw (Cui et al., 2023) et DISC-LawLLM (Yue et al., 2023), développés pour le droit chinois, augmentent un modèle génératif par une base de connaissances juridique structurée pour réduire le risque d'hallucination. Ils constituent des précédents architecturaux pertinents, mais aucun ne dispose d'un mécanisme de vérification formelle de la conformité normative des réponses produites.

CLAUDETTE (Lippi et al., 2019) détecte automatiquement les clauses potentiellement abusives dans les contrats en référence à la directive européenne sur les clauses déloyales, selon un pipeline articulant représentation formelle des exigences réglementaires, extraction des dispositions pertinentes et vérification de correspondance. Son architecture constitue un précédent direct pour la conception de systèmes de conformité normative automatisée, bien qu'elle soit limitée à des tâches de classification binaire sans raisonnement multi-sauts.

PROLEG (Sato et al., 2011), fondé sur les Answer Set Programs pour le droit civil japonais, permet de vérifier formellement l'application d'une règle juridique à un ensemble de faits et de détecter les conflits normatifs. Il représente l'aboutissement le plus rigoureux des

approches purement symboliques, dont la fragilité face aux formulations ambiguës et aux évolutions législatives illustre précisément les limites que les architectures hybrides cherchent à dépasser.

La revue de ces systèmes connexes confirme une tendance convergente : plus un système s'approche des exigences réelles du raisonnement juridique, vérification normative, raisonnement multi-sauts, traçabilité des sources, plus il se heurte aux limites d'une approche monolithique, qu'elle soit purement neuronale ou purement symbolique.

1.11 Synthèse critique et positionnement de la contribution

La revue conduite dans ce chapitre révèle une fragmentation structurelle des approches existantes dont les limites peuvent être organisées autour de trois lacunes principales, constituant autant de défis ouverts dans la littérature.

La première lacune concerne l'absence de vérification ontologique en temps réel. Les systèmes fondés sur les LLMs seuls, qu'ils soient augmentés par retrieval vectoriel ou graphique, produisent des réponses fluides mais non vérifiées contre une base formelle de connaissances normatives. L'absence d'un tel mécanisme expose ces systèmes au risque d'assertions normativement incorrectes ou contradictoires, ce qui est inacceptable dans un contexte où la précision est une exigence à la fois déontologique et légale. Les travaux de Khorshidi et al. (2025) montrent qu'une vérification post-hoc par un second LLM réduit substantiellement ce risque, mais cette approche ne garantit pas la cohérence logique au sens formel : seul un raisonneur symbolique ancré dans une ontologie de domaine est capable de certifier qu'une réponse est compatible avec l'ensemble d'une hiérarchie normative.

La deuxième lacune touche à la rigidité des systèmes purement symboliques. Les ontologies et les graphes de connaissances offrent une rigueur formelle élevée mais souffrent d'un manque d'interface en langage naturel et d'une rigidité face à la variabilité lexicale. Ils ne peuvent pas répondre de manière adaptative à des requêtes formulées dans des termes non prévus par l'ontologie, ce qui les rend pratiquement inutilisables sans une couche de médiation linguistique. De surcroît, leur construction manuelle et leur maintenance face à l'évolution législative représentent un coût opérationnel considérable, particulièrement dans un domaine aussi dynamique que le droit de l'environnement marin.

La troisième lacune est celle du déficit de transparence dans la génération. Les approches RAG classiques et les architectures GraphRAG améliorent la traçabilité par rapport aux LLMs purs, mais ne raisonnent pas sur la hiérarchie des normes récupérées ni sur leurs

interactions logiques. Un système peut ainsi récupérer des passages sémantiquement pertinents sans identifier la dérogation qui en modifie la portée ou la norme supérieure qui en conditionne l'application, produisant une réponse techniquement fondée sur des sources réelles mais normativement erronée.

Dans ce contexte, ce mémoire se positionne à l'interface des approches symboliques et neuronales, en proposant une architecture hybride spécifiquement conçue pour le droit de l'environnement marin. Cette architecture repose sur une structuration progressive en trois niveaux, fondée sur l'hypothèse que la qualité du raisonnement juridique automatisé dépend avant tout de la qualité de la représentation formelle du corpus normatif. Le premier niveau consiste en la construction d'une ontologie de domaine, qui formalise les concepts juridiques, les obligations, les acteurs ainsi que les relations hiérarchiques et les mécanismes de dérogation, constituant ainsi le socle épistémique du système. Le deuxième niveau repose sur la construction d'un graphe de connaissances juridiques ancré dans cette ontologie, permettant de représenter explicitement les dépendances, hiérarchies et interactions entre normes, tout en facilitant leur interrogation et leur exploitation. Enfin, le troisième niveau met en œuvre un système de question-réponse fondé sur le paradigme RAG, combinant une indexation vectorielle des documents et un enrichissement sémantique assuré par le graphe de connaissances. Ce double ancrage, à la fois textuel et structurel, permet de désambiguïser les concepts juridiques, de rendre explicites les relations inter-normes et d'ancrer les réponses générées dans un contexte normatif cohérent, contribuant ainsi à réduire les hallucinations et à améliorer la précision et la fiabilité du raisonnement juridique automatisé.

Le tableau suivant synthétise le positionnement comparatif de l'approche proposée par rapport aux principales familles de systèmes recensés dans cet état de l'art.

Approche	NL fluide	Rigueur formelle	Traçabilité	Vérif. ontologique
LLM seul	✓✓	X	X	X
RAG vectoriel	✓✓	X	Partielle	X
Ontologie / KG seul	X	✓✓	✓✓	✓✓

GraphRAG (Edge et al., 2024)	✓✓	Partielle	✓	✗
OG-RAG (Sharma et al., 2025)	✓✓	✓	✓✓	Partielle
SymRAG (Hakim et al., 2025)	✓✓	✓	✓	✗
Approche proposée	✓✓	✓✓	✓✓	✓✓

Tableau 1.1 — Positionnement comparatif des approches existantes et de la contribution proposée. NL : interface en langage naturel. ✓✓ = pleinement supporté ; ✓ = partiellement supporté ; Partielle = support limité ; ✗ = absent.

Chapitre 2 : Analyse du Domaine et Spécification des Besoins

2.1 Analyse du domaine juridique de l’environnement marin

2.1.1 Le droit de l'environnement marin : définition et enjeux

Le droit de l'environnement marin est le cadre juridique qui vise à assurer la protection, la préservation et la restauration de l'océan et de ses écosystèmes. Il s'agit d'une branche du droit qui cherche à limiter ou supprimer l'impact négatif des activités humaines sur le milieu marin. Il répond à une réalité physique incontournable : l'océan couvre plus de 70 % de la surface terrestre et constitue le plus grand réservoir de biodiversité de la planète, tout en étant soumis à des pressions anthropiques croissantes, surpêche, pollutions diverses, destructions côtières et extraction non contrôlée de ressources.

Ce corpus juridique se distingue par deux caractéristiques majeures. D'une part, il est fondamentalement transfrontalier : les mers ne connaissent pas de frontières, ce qui impose une coopération internationale et une hiérarchie normative complexe. D'autre part, il est fortement technique : les normes ne peuvent être élaborées sans une connaissance approfondie des sciences marines, de l'écologie et des pratiques économiques concernées. Le droit de l'environnement marin s'organise selon une architecture pyramidale. Au sommet, les conventions-cadres internationales posent les principes (UNCLOS, CBD). À un niveau intermédiaire, des instruments sectoriels spécialisés régissent des domaines précis : la chasse

à la baleine (ICRW), la pollution maritime (MARPOL), les espèces migratrices (CMS). À la base, les législations nationales telles que décrets, arrêtés, codes de l'environnement transposent et appliquent ces engagements internationaux dans chaque ordre juridique interne.

2.1.2 Les six domaines d'interdiction couverts par notre corpus

Notre système se concentre sur six thématiques d'interdiction qui représentent les principales menaces anthropiques pesant sur les écosystèmes marins en Afrique de l'Ouest et du Nord. Chacune est encadrée par un régime juridique international spécifique, dont les États côtiers étudiés ont l'obligation de se doter d'un équivalent en droit national.

1. Interdiction de la chasse à la baleine

Les cétacés ou baleines, dauphins et marsouins sont parmi les espèces marines les plus vulnérables à la surexploitation. La chasse commerciale intensive au XX^e siècle a conduit plusieurs espèces au bord de l'extinction. En réponse, la Convention Internationale pour la Régulation de la Chasse à la Baleine (ICRW, 1946) a institué la Commission Baleinière Internationale (CBI) et décrété en 1982 un moratoire sur la chasse commerciale, entré en vigueur en 1986. Ce moratoire reste en vigueur aujourd'hui. En Afrique de l'Ouest, bien que les grands cétacés ne fassent pas l'objet de chasse commerciale directe, leur protection implique des mesures contre les captures accidentelles (by-catch) et la perturbation de leurs habitats.

2. Réglementation de la construction sur le littoral

Le littoral est un espace géographique d'une valeur écologique et économique exceptionnelle. Il abrite les mangroves, les herbiers marins, les récifs coralliens et les zones de frayères essentielles à la reproduction des espèces. La pression urbanistique et touristique entraîne une artificialisation irréversible de ces milieux. Le droit international, notamment à travers le **Protocole sur la Gestion Intégrée des Zones Côtières (GIZC)** de la Convention de Barcelone (2008), impose une planification stricte des constructions en zone littorale : bande non-aedificandi, étude d'impact environnemental obligatoire, préservation des cordons dunaires et des zones humides côtières.

3. Protection des oiseaux marins

Les oiseaux marins sternes, fous, pélicans, frégates, albatros jouent un rôle d'indicateurs écologiques de la santé des océans. Ils sont menacés par la pêche aux palangres (noyade

accidentelle), la pollution plastique, la destruction de leurs sites de nidification et le dérangement humain. La Convention sur les Espèces Migratrices (CMS, 1979) et son Accord sur la Conservation des Oiseaux d'Eau Migrateurs d'Afrique-Eurasie (AEWA) imposent aux États de protéger les espèces listées, leurs habitats critiques et leurs couloirs migratoires. Sur la façade atlantique africaine, ces engagements se traduisent par la création de zones de protection et l'encadrement des activités de pêche dans les zones de nidification.

4. Interdiction de l'extraction de sable marin

L'extraction de sable dans les fonds marins et sur les plages constitue une menace croissante et souvent sous-estimée. Le sable marin est le deuxième matériau le plus consommé dans le monde après l'eau. Son extraction entraîne l'érosion côtière accélérée, la destruction des habitats benthiques, la turbidité des eaux et la déstabilisation des écosystèmes récifaux. La Convention sur la Diversité Biologique (CBD, 1992) fournit le cadre international principal, imposant aux États de réglementer les activités susceptibles d'affecter significativement la biodiversité marine. De nombreux pays d'Afrique de l'Ouest ont instauré des moratoires partiels ou des procédures d'autorisation spécifiques pour encadrer cette activité.

5. Interdiction des rejets d'hydrocarbures en mer

La pollution par les hydrocarbures qu'elle soit opérationnelle (dégazage, déballastage) ou accidentelle (naufrages, échouages) constitue l'une des formes de pollution marine les plus dévastatrices. Elle affecte les oiseaux marins, les mammifères, les poissons et les ressources halieutiques sur lesquelles vivent les populations côtières. La convention MARPOL 73/78 (Convention internationale pour la prévention de la pollution par les navires) est le principal instrument international : son Annexe I réglemente les rejets d'hydrocarbures avec des seuils stricts selon les zones (zones spéciales, haute mer).

6. Interdiction du chalutage de fond

Le chalutage de fond est une technique de pêche qui consiste à traîner sur les fonds marins d'immenses filets lestés. Si elle est efficace à court terme, elle détruit irrémédiablement les écosystèmes benthiques, récifs froids, coraux d'eaux profondes, habitats structurants et capture de grandes quantités de prises accessoires non ciblées. Les Résolutions de l'Assemblée Générale de l'ONU A/RES/61/105 (2007), 64/72 (2010), 66/68 (2012) et 71/123 (2017) appellent les États à interdire ou encadrer strictement le chalutage de fond dans les zones marines vulnérables. Cette interdiction est particulièrement critique dans les ZEE

ouest-africaines, dont les fonds riches constituent des zones de reproduction essentielles pour de nombreuses espèces commerciales.

Enjeu de représentation : La difficulté centrale est que les textes nationaux n'utilisent pas toujours la terminologie des conventions internationales. Un pays peut parler de « grands mammifères marins » là où la convention cite « cétacés », ou d'« activités extractives littorales » là où l'on vise l'extraction de sable. Un système d'intelligence artificielle couplant graphe de connaissances ontologique et recherche sémantique vectorielle permet de surmonter ces discontinuités terminologiques et d'assurer une correspondance fiable entre les deux niveaux normatifs.

2.2 Présentation et caractérisation du corpus documentaire

Le succès d'un système RAG repose sur la qualité, la diversité et la cohérence de son corpus. Notre projet articule deux ensembles documentaires complémentaires : un corpus ontologique à vocation internationale servant de référentiel normatif, et un corpus RAG composé de textes de droit national servant de base de réponse.

2.2.1 Le Corpus Ontologique (Droit International)

Ce corpus constitue la base normative de référence pour la construction du graphe de connaissances Neo4j. Il regroupe les grandes conventions internationales relatives à la protection de l'environnement marin, structurées selon les six catégories thématiques présentées en 2.1.2.

Catégorie	Document	Organisme émetteur	Année	Pages
Baleine	ICRW – Convention Internationale pour la Régulation de la Chasse à la Baleine (révisée 2024)	Commission Baleinière Internationale (CBI)	1946/2024	17
Chalutage de fond	Résolution A/RES/61/105 – Pêches durables	Assemblée Générale ONU	2007	23

Catégorie	Document	Organisme émetteur	Année	Pages
Chalutage de fond	Résolution A/RES/64/72 – Pêches durables	Assemblée Générale ONU	2010	29
Chalutage de fond	Résolution A/RES/66/68 – Pêches durables	Assemblée Générale ONU	2012	32
Chalutage de fond	Résolution A/RES/71/123 – Pêches durables	Assemblée Générale ONU	2017	44
Oiseaux marins	CMS – Convention sur les espèces migratrices (Accord AEWA)	PNUE / CMS	1979	6
Rejet d'hydrocarbure	Protocole de 1978 relatif à MARPOL (Annexe I consolidée)	OMI	1978/2004	81
Rejet d'hydrocarbure	Protocole méditerranéen sur la pollution (Convention de Barcelone)	PNUE / PAM	1994	30
Rejet d'hydrocarbure	Règlement UEMOA n°06/2022 – Normes offshore	Conseil UEMOA	2022	42
Construction littorale	Protocole GIZC Méditerranée (Gestion Intégrée des Zones Côtières)	Convention de Barcelone	2008	21
Construction littorale	Loi Littoral française n°86-2 (référence comparative)	Légifrance	1986/2021	7

Catégorie	Document	Organisme émetteur	Année	Pages
Extraction de sable	CBD – Convention sur la Diversité Biologique	Nations Unies	1992	32

Format et transformation : Ces textes, initialement en PDF, seront transformés en triplets RDF/OWL pour modéliser les relations sémantiques (classes, propriétés, instances), puis migrés vers Neo4j pour permettre des requêtes Cypher performantes sur le graphe de connaissances.

2.2.2 Le Corpus RAG (Droit National)

Ce corpus constitue la base de connaissances textuelle pour la génération de réponses. Il couvre les législations nationales de 15 pays d'Afrique de l'Ouest et du Nord, organisées selon les six catégories thématiques.

- ❖ **Volume total :** 99 documents répartis sur 15 pays.
- ❖ **Thématiques :** Baleine, Oiseaux marins, Rejet d'hydrocarbure, Chalutage de fond, Construction littorale, Extraction de sable.
- ❖ **Format et langue :** Documents majoritairement au format PDF (numériques ou scans de journaux officiels), rédigés principalement en français.
- ❖ **Complexité :** Structure hétérogène, de l'arrêté ministériel court au décret présidentiel complexe, nécessitant une segmentation (chunking) intelligente respectant la hiérarchie des articles de loi.

2.3 Analyse des besoins fonctionnels

Les besoins fonctionnels ont été définis à partir des cas d'usage réels. L'enjeu central est de traiter des questions dites compositionnelles, c'est-à-dire des requêtes combinant une thématique principale avec de multiples conditions spécifiques telles que des exceptions, des zonages ou des modalités de contrôle. Chaque besoin est directement relié aux spécificités du domaine juridique décrit.

2.3.1 Recherche hybride à deux étages et granularité sémantique

Le corpus couvre de multiple pays possédant chacun leur propre phraséologie juridique. Le système doit dépasser la simple correspondance lexicale afin de repérer des nuances extrêmement précises. Il repose à cet effet sur trois composantes distinctes :

- **Recherche de premier niveau (Retrieval large)** : une approche hybride fusionnant la recherche vectorielle dense, destinée à capturer le contexte global et les relations conceptuelles, et la recherche par mots-clés de type BM25, qui garantit l'exactitude des références légales et des numéros d'articles.
- **Fusion à rang réciproque (RRF)** : un mécanisme de combinaison mathématique des différents modèles de recherche, produisant un classement unique et robuste.
- **Re-classement sémantique profond (Cross-Encoder Reranking)** : un modèle de second niveau évaluant avec précision la pertinence entre la requête et le texte extrait, permettant de faire remonter des éléments spécifiques fréquemment noyés dans des corpus volumineux, tels que des dérogations ou des périmètres d'application stricts.

2.3.2 Enrichissement ontologique et comblement des lacunes normatives

Le graphe de connaissances Neo4j constitue un moteur de raisonnement dynamique activé par un agent ontologique dédié. Il remplit trois fonctions principales :

- **Désambiguïsation terminologique (Synonymie inter-pays)** : établir des correspondances entre termes équivalents afin qu'une requête permette de retrouver l'information indépendamment des variations lexicales propres à chaque ordre juridique national.
- **Enrichissement multi-sauts (Multi-hop)** : relier une réglementation nationale à sa source internationale pour offrir à l'utilisateur un contexte normatif complet, au-delà du seul document consulté.
- **Détection de lacunes normatives (Coverage gaps)** : lorsque les textes d'un pays ne couvrent pas un domaine exigé par le droit international, le système signale explicitement cette absence de réglementation.

2.3.3 Analyse d'intention et routage intelligent

Le système doit identifier l'intention juridique et la portée technique sous-jacentes à chaque requête. Il assure deux fonctions à cet égard :

- **Détection des intentions granulaires** : identifier automatiquement si la requête explore des conditions matérielles, géographiques ou temporelles, ou si elle interroge le cadre institutionnel relatif aux procédures de contrôle et aux régimes de sanctions applicables.

- **Filtrage multi-critères** : isoler les documents par périmètre géographique détecté automatiquement dans la formulation de la requête soumise par l'utilisateur.

2.3.4 Traçabilité absolue et politique de zéro hallucination

Dans un contexte d'audit juridique, une réponse plausible mais approximative ou dépourvue de fondement textuel est rigoureusement inacceptable. Le système doit impérativement respecter trois exigences :

- **Justification par citation exacte** : fournir systématiquement le passage exact du texte sur lequel la réponse repose, accompagné des métadonnées irréfutables de la source, à savoir le nom du document, le pays concerné et la nature du texte.
- **Différenciation des correspondances partielles et exactes** : lorsque le système identifie une notion juridique voisine sans qu'elle satisfasse précisément la condition formulée, il doit explicitement signaler cette nuance sans l'assimiler à une correspondance exacte.
- **Contraintes de négation strictes** : lorsqu'une question impose une condition stricte et que le texte applicable ne la mentionne pas, le système a pour instruction formelle de répondre par la négative, toute extrapolation étant proscrite.

2.4 Analyse des besoins non fonctionnel

- ❖ **Précision et fiabilité** : Dans le domaine légal, l'absence d'hallucinations est critique. Le système doit privilégier le refus de réponse (« Je ne dispose pas d'informations suffisantes ») plutôt qu'une réponse juridiquement inexacte.
- ❖ **Performance** : Le temps de réponse pour une recherche hybride complexe ne doit pas excéder 3 à 5 secondes en conditions nominales. Les requêtes nécessitant un parcours du graphe Neo4j (multi-sauts) doivent rester sous 8 secondes.
- ❖ **Explicabilité** : L'utilisateur doit pouvoir comprendre pourquoi un document a été jugé pertinent : visualisation du chemin ontologique emprunté, score de similarité affiché, chunk source rendu accessible.
- ❖ **Scalabilité** : L'architecture doit permettre l'ajout de nouveaux pays, de nouvelles catégories thématiques ou de nouvelles conventions internationales sans refonte du moteur de recherche.

2.5 Modélisation et spécification du système

Le système est modélisé autour d'un acteur principal : l'expert juridique. Ce profil requiert un accès rapide, fiable et traçable aux textes juridiques afin d'évaluer la conformité environnementale des pays cibles. L'interaction avec le système a été volontairement simplifiée au maximum via une interface de dialogue en langage naturel.


2.5.1 Cas d'utilisation unique : Interrogation réglementaire multi-thématique

Le système repose sur un seul cas d'utilisation central :

Poser une question sur une thématique environnementale maritime : L'utilisateur saisit une question en langage naturel portant sur l'une des problématiques maritimes ciblées, telles que le chalutage de fond, la protection des cétacés ou les rejets d'hydrocarbures. Le système prend en charge l'intégralité du traitement : compréhension de l'intention, désambiguïsation terminologique via l'ontologie, recherche dans le corpus du pays concerné, et restitution d'une réponse claire accompagnée de la citation exacte du texte de loi. L'utilisateur obtient une réponse dans tous les cas, qu'il s'agisse d'une réglementation existante ou d'un vide juridique.

2.5.2 Diagramme de séquence

Le diagramme de séquence ci-dessous illustre les interactions entre l'utilisateur et les différents composants internes du système lors d'une interrogation. Il met en évidence le rôle de chaque composant ainsi que l'ordre de traitement depuis la saisie de la question jusqu'à la restitution de la réponse.



Description des étapes :


- **Étape 1 - Analyse de la requête :** le Query Analyzer détecte automatiquement le pays visé ainsi que la granularité de l'intention, en distinguant par exemple une

question portant sur une zone géographique, une sanction pénale ou une procédure de contrôle. C'est également à cette étape qu'intervient la désambiguïsation terminologique : si l'utilisateur emploie le terme "baleine", le système interroge l'agent ontologique Neo4j pour identifier les synonymes associés, avant de lancer la recherche.

- **Étape 2 - Recherche hybride** : la requête interroge simultanément la base vectorielle ChromaDB, l'index lexical BM25 et le graphe de connaissances Neo4j, garantissant une couverture maximale du corpus.
- **Étape 3 - Fusion et re-classement** : les résultats sont unifiés mathématiquement par le mécanisme RRF, puis analysés par un modèle Cross-Encoder qui évalue mot à mot la pertinence de chaque fragment par rapport à la question posée.
- **Étape 4 - Génération sécurisée** : le contexte affiné est transmis au modèle de langage avec des instructions strictes dérivées de l'analyse initiale, interdisant toute extrapolation et imposant une réponse négative explicite lorsque le texte ne couvre pas la condition recherchée.

2.5.3 Diagramme d'activité d'indexation RAG

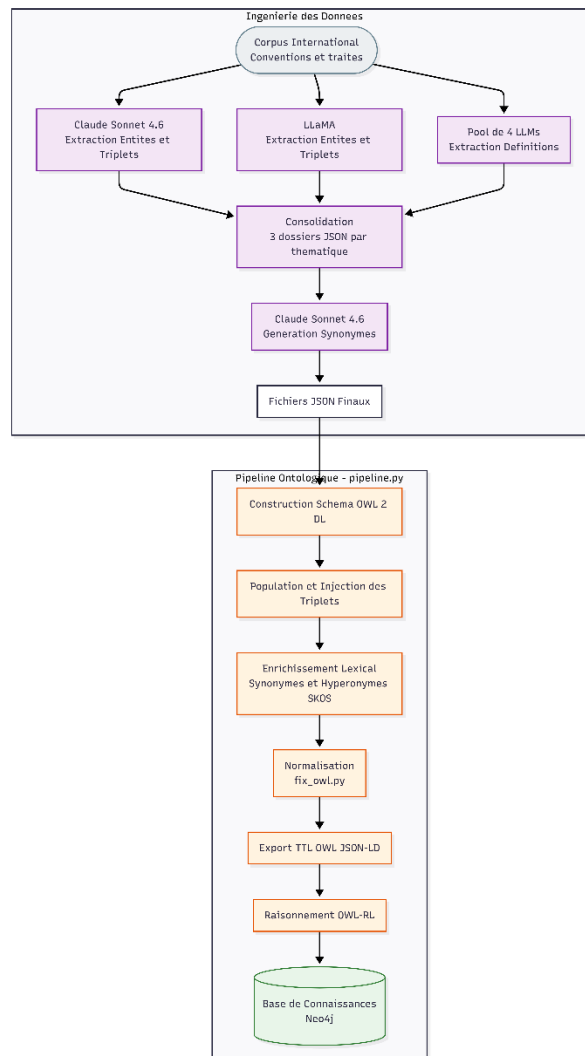
Le pipeline d'indexation RAG traite les textes juridiques nationaux avant toute interrogation. Il repose sur une extraction avancée via PyMuPDF, capable de détecter et de convertir les tableaux en Markdown, suivie d'un nettoyage non-destructif adapté aux textes juridiques qui supprime les artefacts PDF sans altérer les références légales. Le découpage est ensuite effectué par unité légale, en identifiant les marqueurs de structure tels que les articles, sections et chapitres. Lorsqu'une unité dépasse la taille maximale autorisée, un sous-découpage par alinéa avec overlap est appliqué. Chaque chunk produit est enrichi d'un score de qualité, d'un hash MD5 pour la déduplication cross-documents, et de métadonnées complètes incluant le pays, le titre du document et la hiérarchie légale sous forme de breadcrumb.



2.5.4 Diagramme d'activité de l'ingestion d'ingénierie des données ontologiques


Le pipeline ontologique traite les textes juridiques internationaux, conventions et traités, afin de construire le graphe de connaissances Neo4j. Les documents bruts sont soumis simultanément à deux modèles pour l'extraction des entités et des triplets : Claude Sonnet 4.6 et LLaMA, dont les résultats sont ensuite consolidés. Un pool de quatre modèles de langage distincts est mobilisé en parallèle pour l'extraction des définitions juridiques. Une fois les données consolidées par thématique dans trois dossiers JSON, Claude Sonnet 4.6 est sollicité une seconde fois pour générer les synonymes associés à chaque entité. Ces fichiers JSON constituent l'entrée du pipeline ontologique, qui assure successivement la construction du schéma OWL 2 DL, la population des individus, l'injection des triplets, l'enrichissement

lexical via les relations SKOS, la normalisation, l'export multi-format et le raisonnement OWL-RL avant l'import final dans Neo4j.




2.5.5 Diagramme de Composants (Architecture Technique Globale)

Ce diagramme montre comment les différentes briques logicielles communiquent entre elles lors d'une recherche.



2.5.6 Diagramme de classe de l'ontologie (Méta-Modèle)

Le diagramme de classes expose le méta-modèle conceptuel de l'ontologie maritime (T-Box), élaboré pour structurer formellement le droit international de l'environnement. Afin d'assurer l'interopérabilité et la robustesse académique du graphe, le modèle n'a pas été construit from scratch, mais s'appuie sur la LKIF-Core Upper Ontology (Legal Knowledge Interchange Format). Ainsi, nos classes maritimes spécifiques héritent des concepts juridiques universels : par exemple, la SourceJuridique dérive de lkif:Document, et l'Interdiction dérive de lkif:Norm. Autour de cette interdiction pivot s'articulent les autres entités du domaine : l'Acteur ciblé, l'Activité régulée, la ZoneGéographique d'application, ainsi que les Sanctions et ExceptionsJuridiques prévues par le texte. De plus, une classe ConceptLexical (basée sur la norme SKOS) est intégrée pour capturer les variations terminologiques inter-États (synonymes). Ce formalisme strict en graphe de propriétés permet non seulement de désambiguïser les textes juridiques, mais également d'offrir au système RAG une capacité de raisonnement multi-sauts indispensable pour l'audit de conformité réglementaire.



Chapitre 3 : Conception et Implémentation de l'Ontologie

3.1 Définition et rôle d'une ontologie dans un système juridique

Une ontologie, au sens informatique du terme, est une représentation formelle et explicite d'un domaine de connaissance. Elle structure les concepts, leurs propriétés et les relations qui les unissent de manière lisible à la fois par les humains et par les machines.

Contrairement à une simple base de données relationnelle, une ontologie est dotée d'une capacité de raisonnement. Elle permet d'inférer de nouvelles connaissances à partir de celles qui sont explicitement encodées, grâce à des moteurs logiques appelés raisonneurs.

Dans le cadre d'un système juridique maritime, le recours à une ontologie répond à un besoin précis : dépasser la simple correspondance lexicale entre une question et un texte de loi. En structurant formellement les concepts du droit maritime, tels que les interdictions, les sanctions, les zones géographiques ou les acteurs juridiques, l'ontologie permet au système de raisonner sur ces concepts, de détecter des incohérences normatives et de naviguer entre les textes de manière multi-sauts, c'est-à-dire en reliant une réglementation nationale à sa source internationale sans intervention humaine.

3.2 Méthodes de construction d'une ontologie

La littérature scientifique distingue trois grandes approches pour la construction d'une ontologie, qui se différencient par le degré d'intervention humaine qu'elles requièrent.

3.2.1 La construction manuelle

Il s'agit de l'approche traditionnelle. Elle repose sur l'expertise d'un ingénieur de la connaissance qui, en collaboration avec des experts du domaine, définit manuellement les concepts, les hiérarchies et les relations. Des méthodologies formalisées telles que Methontology, développée par l'Université Polytechnique de Madrid, ou On-To-Knowledge encadrent ce processus en proposant des étapes structurées allant de la spécification des besoins jusqu'à la validation.

Si cette approche garantit une grande précision conceptuelle, elle souffre de limites importantes en termes de passage à l'échelle et de coût humain, particulièrement dans des domaines aussi volumineux que le droit maritime.

3.2.2 La construction automatique

Cette approche s'appuie sur des techniques d'apprentissage automatique et de traitement du langage naturel pour extraire automatiquement les concepts et les relations à partir de corpus textuels. Des méthodes telles que l'extraction de terminologie, la classification automatique ou l'alignement d'ontologies existantes permettent de produire rapidement une structure ontologique à partir de grandes quantités de documents.

Cependant, la qualité des résultats reste tributaire de la nature du corpus et nécessite une validation humaine pour garantir la cohérence logique de l'ensemble.

3.2.3 La construction semi-automatique

C'est l'approche adoptée dans ce projet. Elle combine les avantages des deux méthodes précédentes : des modèles de langage de grande taille sont utilisés pour produire une première version du graphe de connaissances à partir des textes bruts, tandis qu'un expert du domaine supervise, corrige et enrichit les résultats obtenus. Cette approche permet d'atteindre un niveau de couverture élevé tout en maintenant une rigueur conceptuelle adaptée aux exigences du domaine juridique.

3.3 Construction de l'ontologie : démarche adoptée

3.3.1 Phase 1 - Spécification des besoins

La construction de l'ontologie a débuté par la définition des questions de compétence, c'est-à-dire l'ensemble des questions auxquelles le système doit être capable de répondre. Cette étape est fondamentale car elle délimite précisément le périmètre du graphe de connaissances et oriente toutes les décisions de modélisation qui suivent. Des questions telles que "Quelles sont les sanctions prévues pour le chalutage de fond au Sénégal ?" ou "Quelles exceptions s'appliquent à l'interdiction de chasse à la baleine ?" ont ainsi servi de boussole tout au long du processus de conception.

Douze questions de compétence ont été formalisées et traduites en requêtes SPARQL, constituant le référentiel de validation de l'ontologie.

3.3.2 Phase 2 - Ingénierie des données

Une fois les besoins spécifiés, les textes juridiques internationaux ont été traités afin d'en extraire les informations structurées nécessaires à la population du graphe. Cette phase a mobilisé plusieurs modèles de langage de manière complémentaire, selon une stratégie en trois volets.

Le premier volet a consisté en l'extraction des entités et des triplets. Les textes bruts ont été soumis simultanément à deux modèles : Claude Sonnet 4.6 et LlamaParser. Ce choix délibéré de mobiliser deux modèles sur les mêmes documents repose sur une logique de complémentarité : chaque modèle possède ses propres forces et ses propres angles morts, et aucun ne garantit à lui seul une extraction exhaustive sur un corpus juridique aussi hétérogène.

Le deuxième volet a porté sur l'extraction des définitions juridiques. Un pool de quatre modèles de langage distincts a été mobilisé en parallèle : Mistral-8B, LlamaParser, Gemma-4-E4B-it et Qwen. Ce choix de mobiliser plusieurs modèles simultanément n'était pas arbitraire : chaque modèle s'est révélé performant sur des types de documents différents, et aucun ne dominait l'ensemble du corpus de manière uniforme.

Le troisième volet a consisté en la génération des synonymes. Claude Sonnet 4.6 a été sollicité dans une passe dédiée pour générer, pour chaque entité extraite, l'ensemble des termes alternatifs susceptibles d'être employés dans les textes nationaux pour désigner la même réalité juridique. Cette étape est directement liée à la construction du pont lexical décrit plus loin.

L'ensemble de ces données produites ont alimenté trois dossiers JSON distincts, organisés par thématique, qui constituent l'entrée du pipeline d'instanciation.

3.3.3 Phase 3 - Modélisation formelle

Sur la base des données extraites et des questions de compétence, le schéma T-Box a été construit de manière programmatique via la bibliothèque Python rdflib. Le choix de générer l'ontologie par le code plutôt que manuellement via l'interface graphique de Protégé présente un avantage majeur : il garantit la reproductibilité totale du modèle, toute modification du schéma étant versionnée et réexécutable à la demande.

Le schéma encode les classes et leurs hiérarchies, les axiomes de disjonction entre sous-classes, les propriétés d'objet et leurs caractéristiques logiques, ainsi que les propriétés de données fortement typées. L'ontologie hérite par ailleurs formellement de la LKIF-Core

Upper Ontology, un standard international pour la représentation des concepts juridiques, ce qui lui confère une assise théorique reconnue et garantit son interopérabilité avec d'autres systèmes.

3.3.4 Phase 4 - Normalisation et correction

Une fois la population du graphe effectuée, une passe algorithmique de normalisation a été appliquée via le script `fix_owl.py`. Cette étape est indispensable pour corriger les imperfections inévitablement introduites par l'extraction automatique. Elle comprend la déduplication des noeuds, par exemple la fusion des entrées "Bénin" et "Republique du Benin" qui désignent le même Etat, la correction des balises de langue, et la gestion des hyperonymes excessifs.

3.3.5 Phase 5 - Validation et raffinement

La dernière phase a consisté à valider l'ontologie à deux niveaux. D'une part, le raisonneur HermiT, intégré à l'environnement Protégé 5.x, a été utilisé pour vérifier la cohérence logique du graphe et s'assurer de l'absence de toute contradiction entre les axiomes. D'autre part, les douze questions de compétence ont été exécutées en SPARQL afin de confirmer que le graphe produit les résultats attendus pour chaque cas d'usage métier.

3.4 Fondation et alignement sur une ontologie de référence

L'ontologie construite dans ce projet ne part pas de zéro. Elle hérite formellement de la LKIF-Core Upper Ontology, un standard international pour la représentation des concepts juridiques développé dans le cadre du projet Estrella. Cet alignement garantit l'interopérabilité avec d'autres systèmes juridiques et confère à l'ontologie une assise théorique reconnue par la communauté scientifique.

Les correspondances d'héritage établies sont les suivantes :

- Les lois maritimes, modélisées par la classe Interdiction, héritent de la classe `lkif:Prohibition`, elle-même sous-classe de `lkif:Norm`.
- Les textes de loi, regroupés sous la classe `SourceJuridique`, héritent de `lkif:Legal_Source`.
- Les entités physiques ou morales, regroupées sous la classe `Acteur`, héritent de `lkif:Agent`.
- Les activités humaines, regroupées sous la classe `Activite`, héritent de `lkif:Act`.
- Les espaces maritimes, regroupés sous la classe `Zone`, héritent de `lkif:Place`.

3.5 Modélisation des concepts métiers

Le cœur de l'ontologie est structuré autour d'entités métiers rigoureusement définies. Cette structuration, communément appelée T-Box dans le formalisme des logiques de description, est organisée en taxonomie avec une règle stricte d'exclusivité mutuelle entre les sous-classes, formalisée par des axiomes de disjonction stricte.

3.5.1 Les normes

L'axe déontique de l'ontologie distingue trois types de normes mutuellement disjoints : l'Interdiction, la Permission et l'Obligation. L'Interdiction constitue la classe pivot de l'ensemble du système, autour de laquelle s'articulent toutes les autres entités.

3.5.2 Les activités

Les activités sont organisées en grandes catégories disjointes, chacune subdivisée en typologies précises :

- *ActivitePêche* regroupe le chalutage de fond, la pêche illicite non déclarée et non réglementée, et la pêche profonde.
- *ActiviteChasse* regroupe la chasse à la baleine, elle-même subdivisée en trois sous-types mutuellement disjoints : la chasse commerciale, la chasse scientifique et la chasse de subsistance.
- *ActiviteExtraction* regroupe l'extraction de sable.
- *ActiviteRejets* regroupe les rejets d'hydrocarbures et les rejets d'eaux usées.
- *ActiviteConstruction* regroupe les constructions littorales.

3.5.3 Les acteurs

L'axe institutionnel distingue plusieurs catégories d'acteurs juridiques :

- *EtatSouverain*, décliné en *Etat du Pavillon*, *Etat Côtier* et *Etat Portuaire*.
- *OrganisationInternationale*, comprenant la *Commission Baleinière Internationale*, l'*Organisation Maritime Internationale* et la *FAO*.
- *NavirePêche* et *NavireUsine*, représentant les unités opérationnelles en mer.
- *OperateurEconomique*, comprenant l'*Armateur* et le *Capitaine*.

3.5.4 La biodiversité

L'axe des espèces protégées inclut notamment la classe *Cetace*, définie formellement par une union disjointe entre *BaleineMysticete*, les baleines à fanons, et *BaleineOdontocete*, les baleines à dents. Cette déclaration formelle permet au raisonneur de savoir qu'il n'existe aucun autre type de cétacé en dehors de ces deux sous-classes. L'ontologie modélise également les oiseaux migrateurs, les tortues marines et les poissons profonds.

3.5.5 Les sanctions et exceptions

Les sanctions se déclinent en deux catégories disjointes : la `SanctionPenale` et la `SanctionAdministrative`. Les exceptions juridiques se distinguent quant à elles entre `ExceptionGenerale` et `ExceptionSpecifique`. Ces classes permettent de modéliser la compositionnalité des lois maritimes, c'est-à-dire la capacité d'une exception à annuler partiellement ou totalement une interdiction.

3.6 Relations sémantiques (Object Properties)

L'intelligence algorithmique de l'ontologie réside dans les relations qui connectent les concepts entre eux, rendant le graphe interrogeable sous forme de triplets RDF. Au total, l'ontologie modélise une richesse sémantique de 41 relations d'objet métier, dont 6 bidirectionnelles, ancrées sur 7 relations fondatrices héritées des standards LKIF-Core et OWL-Time, telles que `lkif:has_exception`, `lkif:prohibited_by` ou `time:hasBeginning`. Ces relations ont été spécifiquement modélisées pour couvrir l'ensemble des dimensions factuelles et normatives du domaine juridique maritime.

3.6.1 Relations primaires

Les relations primaires sont :

institueNorme relie une source juridique à l'interdiction qu'elle édicte.

concerneActivite relie une interdiction à l'activité qu'elle prohibe.

concerneActeur relie une interdiction à l'acteur juridique qu'elle cible.

protegeEspece relie une interdiction à l'espèce animale qu'elle a vocation à protéger, telle que le Cétacé.

appliesInZone relie une interdiction à la zone géographique dans laquelle elle s'applique.

appliesDuring relie une interdiction à la période temporelle durant laquelle elle est en vigueur.

entraîneSanction relie une interdiction à la sanction associée en cas de violation.

soumisAControle relie une interdiction au mécanisme de contrôle institutionnel qui en assure l'application.

aException relie une interdiction à l'exception juridique qui peut en suspendre la portée.

hasConcept relie une entité à un concept lexical SKOS, permettant d'attacher des dictionnaires de synonymes au graphe, ce qui est essentiel pour la résolution NLP dans le système hybride RAG.

3.6.2 Propriétés inverses et navigation bidirectionnelle

Afin de garantir une navigation sémantique fluide dans n'importe quel sens d'interrogation, six relations fondamentales ont été appairées à leur propriété inverse par le biais de

owl:inverseOf. Cette symétrie est indispensable pour l'interrogation SPARQL, qui doit pouvoir traverser le graphe dans les deux directions selon la nature de la requête formulée.

estActiviteDe est la propriété inverse de `concerneActivite`. Un agent IA cherchant quelles activités sont interdites par une norme donnée utilisera `concerneActivite`, tandis qu'une requête cherchant par quelles lois une activité est régie mobilisera `estActiviteDe`.

estZoneDe est la propriété inverse de `appliesInZone`, permettant d'interroger le graphe à partir d'une zone géographique pour remonter aux interdictions qui s'y appliquent.

estActeurConcernePar est la propriété inverse de `concerneActeur`, permettant d'identifier l'ensemble des interdictions auxquelles un acteur donné est soumis.

estExceptionDe est la propriété inverse de `aException`, permettant de retrouver l'interdiction qu'une exception juridique vient suspendre.

estSanctionDe est la propriété inverse de `entraîneSanction`, permettant de remonter d'une sanction à l'interdiction qui la fonde.

3.7 Axiomatisation et contraintes logiques (OWL 2 DL)

Pour garantir que le moteur d'inférence, tel que HermiT, puisse raisonner correctement sur le graphe et détecter les incohérences structurelles, l'ontologie a été enrichie d'axiomes logiques conformes au profil OWL 2 DL.

Contrairement aux ontologies académiques traditionnelles, souvent surchargées de restrictions existentielles dédiées à la classification automatique, notre approche privilégie le paradigme de la Lightweight Ontology. Dans une architecture hybride neuro-symbolique de type GraphRAG, la classification fine est déjà prise en charge par les modèles de langage lors du pipeline d'ingestion. Le rôle de l'axiomatisation n'est donc pas de faire deviner des concepts à la machine, mais de constituer un filet de sécurité strict pour empêcher les LLMs d'halluciner lors de la restitution. À cette fin, l'ontologie intègre 60 axiomes logiques avancés, répartis comme suit : 44 axiomes de disjonction de classes, 9 axiomes de caractéristiques de propriétés, 6 axiomes de relations inverses déjà détaillés en section 3.6.2, et 1 axiome de couverture exhaustive. Les trois premiers types sont développés dans les sous-sections suivantes.

3.7.1 Disjonction de classes (owl:disjointWith)

Dans le domaine du droit, lever les ambiguïtés catégorielles est essentiel. L'ontologie intègre à cet effet 44 axiomes de disjonction stricte, répartis en 10 blocs thématiques.

Une `SanctionPenale` est ainsi mathématiquement disjointe d'une `SanctionAdministrative`. L'`EtatSouverain` est disjoint du `NavirePêche`. Le `ChalutageFond` est disjoint de la `PêcheINN`.

Ce verrouillage formel empêche le système d'instancier par erreur une entité possédant deux types incompatibles simultanément, qu'il s'agisse d'une erreur de modélisation ou d'une hallucination produite par un modèle de langage.

3.7.2 Couverture exhaustive (owl:disjointUnionOf)

Cet axiome a été utilisé pour imposer une taxonomie fermée sur la biodiversité marine. La classe Cétacé a été définie formellement comme l'union disjointe stricte de BaleineMysticete et BaleineOdontocete. Le raisonneur sait ainsi qu'il n'existe aucune autre sous-catégorie possible de cétacé dans l'univers du graphe, forçant les modèles extracteurs à se conformer à ce standard binaire sans déviation possible.

3.7.3 Propriétés mathématiques et directionnelles

Afin de doter le graphe de capacités de déduction sans alourdir le temps de calcul lors de l'interrogation par le RAG, 9 axiomes de caractéristiques de propriétés ont été encodés.

couvreZone est déclarée transitive au sens de owl:TransitiveProperty. Le raisonneur déduit que si une zone A couvre une zone B et que B couvre une zone C, alors A couvre implicitement C, sans que cette relation n'ait été explicitement saisie dans l'ontologie.

bordeZone est déclarée symétrique au sens de owl:SymmetricProperty. Si la zone A borde la zone B, le système conclut automatiquement que B borde A, garantissant la cohérence du graphe géographique sans redondance de saisie.

entraîneSanction possède les propriétés asymétrique et irréflexive, exprimées respectivement par owl:AsymmetricProperty et owl:IrreflexiveProperty. Ces contraintes introduisent une directionnalité stricte qui empêche logiquement toute sanction de s'auto-engendrer dans le réseau, préservant ainsi l'intégrité formelle du modèle.

Ce choix d'axiomatisation offre un compromis entre une rigueur sémantique intraitable, indispensable pour l'audit juridique maritime, et une haute performance computationnelle permettant une interrogation en temps réel par l'application finale

3.8 Le pont lexical

L'une des contributions majeures de cette ontologie pour le système RAG est la classe ConceptLexical, fondée sur le standard SKOS. Elle permet d'attacher des dictionnaires de synonymes à la structure formelle du graphe, surmontant ainsi l'hétérogénéité terminologique entre les quinze pays étudiés.

Concrètement, l'activité ChasseBaleine est liée à un ConceptLexical qui contient le terme préférentiel "Chasse à la baleine" ainsi que plusieurs synonymes générés par Claude Sonnet 4.6, tels que "Capture de grands cétacés" ou "Whaling". Lorsqu'un utilisateur pose une

question en employant le terme courant "baleine", le système consulte ce pont lexical pour identifier le terme juridiquement exact utilisé dans les textes, à savoir "cétacé", avant de lancer la recherche dans le corpus.

Ce mécanisme garantit qu'aucune information réglementaire ne soit manquée en raison d'une simple variation de vocabulaire entre pays.

3.9 Validation de l'ontologie

La validation du graphe de connaissances a été conduite à trois niveaux complémentaires.

La cohérence logique a été vérifiée en soumettant l'ontologie exportée au raisonneur HermiT, intégré à l'environnement Protégé 5.x. Le raisonneur n'a identifié aucune classe insatisfaisable, confirmant l'absence de toute contradiction logique entre les axiomes de disjonction et les restrictions définies dans la T-Box.

L'évaluation fonctionnelle a consisté à valider la capacité de l'ontologie à répondre aux exigences métier au travers des douze questions de compétence formulées en SPARQL. Ces requêtes couvrent des cas complexes tels que l'identification des exceptions liées à une interdiction de chalutage ou la recherche de toutes les sanctions applicables à un acteur dans une zone donnée. Les résultats confirment que le graphe permet d'extraire la bonne réponse pour chaque question posée, établissant ainsi la justesse du maillage relationnel construit.

Les mesures de qualité ont porté sur deux dimensions principales. La couverture a été évaluée au regard des six grandes thématiques d'interdictions environnementales maritimes ciblées par le projet, et l'alignement s'est révélé exhaustif. La précision a quant à elle été vérifiée en s'assurant de l'absence de collision entre les catégories d'acteurs, notamment entre les Etats souverains et les navires de pêche, grâce aux axiomes de disjonction définis dans la T-Box.

Chapitre 4 : Construction du Graphe de Connaissances

Ce chapitre retrace le processus de construction du graphe de connaissances maritime. L'objectif était de partir de textes juridiques bruts et d'aboutir à une représentation exploitable dans une base Neo4j. Sont décrits successivement l'extraction des entités et des relations, la transformation de l'ontologie OWL vers le modèle de graphe de propriétés, l'architecture de la base obtenue, son analyse structurelle, puis les limites identifiées en cours de route.

4.1 Extraction des connaissances à partir du texte

Transformer des textes juridiques bruts en triplets RDF structurés constitue la première étape, et sans doute la plus délicate, de toute la chaîne de traitement. Cette opération repose sur deux tâches complémentaires : la reconnaissance d'entités nommées (NER) et l'extraction de relations. Le corpus maritime, composé de conventions internationales rédigées dans un langage juridique particulièrement formel, ne se prêtait pas à une approche mono-modèle : une stratégie multi-modèles a donc été adoptée afin de maximiser à la fois l'exhaustivité et la précision.

4.1.1 Stratégie multi-modèles pour l'extraction des triplets

La première phase du pipeline consiste à produire des triplets RDF de la forme {Sujet, Prédicat, Objet} à partir des documents. Plutôt que de s'appuyer sur un seul modèle, une comparaison a été conduite entre deux systèmes aux architectures très différentes : Claude Sonnet 4.6 et LlamaParser.

Ce choix s'est révélé pertinent, car les deux modèles ne traitent clairement pas les textes de la même façon. Sur l'interdiction relative au chalutage de fond (I001), Claude Sonnet 4.6 a extrait 31 entités et 39 triplets, quand LlamaParser en a produit respectivement 70 et 200, avec seulement 29 triplets en commun. L'écart est encore plus frappant sur l'interdiction relative aux baleines (I002) : Claude Sonnet 4.6 s'est limité à 38 entités et 40 triplets, tandis que LlamaParser en a fourni 331 et 329, avec à peine 6 triplets partagés.

Interdiction	Modèle	Entités extraites	Triplets extraits	Triplets communs
I001 - Chalutage de fond	Claude Sonnet 4.6	31	39	29
I001 - Chalutage de fond	LlamaParser	70	200	29
I002 - Chasse baleine	Claude Sonnet 4.6	38	40	6
I002 - Chasse baleine	LlamaParser	331	329	6

Tableau 4.1 - Comparaison des résultats d'extraction entre Claude Sonnet 4.6 et LlamaParser

Ces chiffres montrent que les deux modèles sont complémentaires plutôt que redondants. Claude Sonnet 4.6 produit des extractions plus concises, en privilégiant la précision sur le

volume. LlamaParser, lui, capture davantage de variantes et de détails techniques, parfois au prix d'un certain bruit. Les résultats des deux modèles ont donc été fusionnés, en conservant l'intégralité des informations sans doublon, dans six fichiers JSON distincts par interdiction. Avant d'aller plus loin, ces données ont été soumises à des experts du domaine juridique maritime. Cette validation a permis de vérifier la cohérence sémantique des entités et triplets produits, de corriger les erreurs résiduelles et de lever les ambiguïtés terminologiques. Elle constitue le dernier filet de sécurité avant que les données n'entrent dans le pipeline ontologique.

4.1.2 Extraction des définitions juridiques

En parallèle de l'extraction des triplets, un second chantier a été ouvert : extraire les définitions juridiques contenues dans les textes. La difficulté ici est que chaque convention internationale possède sa propre terminologie, et que la précision des définitions est directement liée à la qualité du raisonnement que le graphe devra supporter.

Pour ce faire, un pool de quatre modèles a été mobilisé en parallèle : Mistral-8B, LlamaParser, Gemma-4-E4B-it et Qwen, en comparant leurs résultats thématiques par thématique. Chacun a montré ses points forts. Mistral-8B s'est distingué sur les documents relatifs aux engins de pêche, là où les termes techniques sont nombreux mais relativement simples. LlamaParser s'est imposé comme référence sur les documents à forte densité scientifique, notamment les conventions ICRW et MARPOL, grâce à sa capacité à restituer avec fidélité les paramètres techniques (noms scientifiques, formules, seuils réglementaires). Gemma-4-E4B-it, quant à lui, a produit les extractions les plus propres sur les définitions juridiques françaises, notamment pour les documents relatifs à la Gestion Intégrée des Zones Côtières et à la Convention sur les Espèces Migratrices.

Une stratégie de sélection par thématique a donc été adoptée : plutôt que de retenir un modèle unique pour l'ensemble du corpus, le meilleur résultat a été conservé domaine par domaine. C'est contraignant, mais c'est ce qui permet d'obtenir une couverture à la fois exhaustive et précise.

4.1.3 Pipeline d'injection qualifiée des triplets

Une fois les triplets produits, leur injection dans le graphe RDF est prise en charge par le module `triple_injector.py`, selon un pipeline en quatre phases.

La Phase 1 est l'injection proprement dite : chaque triplet JSON de la forme {sujet, prédicat, objet} est transformé en un arc RDF réel dans le graphe. Les prédicats bruts issus des modèles sont normalisés via une table de correspondance (PREDICATE_MAP). Par exemple, le

prédicat `mar:admetException`, produit tel quel par un LLM, est automatiquement réécrit en `mar:aException`, qui correspond à la propriété d'objet définie dans la T-Box de l'ontologie. En amont de cette injection, un filtre de confiance élimine les triplets dont le score attribué par le modèle est inférieur à 0,8 (`CONFIDENCE_THRESHOLD`). Ce seuil permet de réduire le bruit sémantique sans sacrifier trop d'informations utiles. Une normalisation géographique est également appliquée : un dictionnaire (`ZONE_MAPPING`) résout les synonymes courants vers un identifiant canonique unique.

La Phase 2 assure le typage OWL des entités extraites par NER : chaque entité est rattachée à la classe OWL appropriée via la table `CATEGORY_TO_OWL_CLASS`. Une entité reconnue comme appartenant à la catégorie « Actor » est automatiquement instanciée comme individu de la classe `mar:Acteur`.

La Phase 3 matérialise les inférences que Neo4j ne peut pas calculer nativement, faute de raisonneur en logique de description. Trois règles sont systématiquement appliquées : toute Zone liée à une Interdiction reçoit le label supplémentaire : `ZoneInterdite` ; toute Activité liée à une Interdiction reçoit le label : `ActiviteIllicite` ; et la chaîne de propriétés `estActiviteDe` est résolue pour produire la relation directe `estSoumisA` entre un Acteur et une Interdiction.

La Phase 4 relie les définitions juridiques retenues au graphe, en créant des arcs `mar:hasConcept` entre chaque nœud Interdiction et les concepts lexicaux SKOS associés.

Un filtre de cohérence transversal complète le dispositif en bloquant les associations sémantiquement absurdes. Par exemple, l'association de l'interdiction I003 (Construction Littorale) à la zone HM (Haute Mer) est systématiquement rejetée : par définition, aucune activité de construction côtière ne peut s'exercer en haute mer.

4.1.4 Génération de la couche lexicale et des synonymes

Un troisième volet du pipeline concerne les synonymes. Claude Sonnet 4.6 a été sollicité dans une passe dédiée pour produire, pour chacune des six interdictions, les termes alternatifs susceptibles d'apparaître dans les textes juridiques nationaux pour désigner la même réalité. Cette étape est rendue nécessaire par la diversité terminologique des quinze pays couverts par le corpus : chaque système juridique national tend à employer ses propres formulations pour désigner des concepts identiques. Un pays utilisera par exemple le terme « baleine » là où un autre recourra à « cétacé », bien que les deux désignent la même réalité biologique et juridique. Ces synonymes sont encodés en RDF via la propriété SKOS `skos:altLabel`. Leur rôle est central dans le système RAG : sans cette couche lexicale, une requête formulée avec une autre terminologie risquerait de ne pas retrouver les documents traitant pourtant du même sujet.

4.2 Passage de l'ontologie OWL vers le graphe de propriétés

L'ontologie OWL 2 DL construite dans le chapitre précédent repose sur un formalisme de logique de description, bien adapté au raisonnement automatique mais difficilement exploitable tel quel pour un système de recherche à grande échelle. La transition vers Neo4j est assurée par le module `neo4j_export.py`, qui traduit les primitives OWL en structures natives du modèle Property Graph.

4.2.1 Mapping des primitives OWL vers Neo4j

La conversion repose sur trois règles de mapping systématiques.

Chaque individu OWL (`owl:NamedIndividual`) devient un nœud Neo4j. Les labels du nœud sont déterminés par résolution des classes OWL auxquelles appartient l'individu, via la table `CLASS_TO_NEO4J_LABEL`. Un individu de la classe `ZoneEconomiqueExclusive` reçoit ainsi les deux labels : `Zone` et `: ZoneEEZ`, ce qui autorise à la fois des requêtes génériques (sur toutes les zones) et des requêtes spécifiques (sur les ZEE). Cette multi-labellisation préserve la sémantique héritée de la hiérarchie de classes OWL.

Chaque propriété d'objet OWL est transformée en type de relation Neo4j, selon la convention `SCREAMING_SNAKE_CASE`. La propriété `appliesInZone` devient la relation `[:APPLIES_IN_ZONE]`, `concerneActeur` devient `[:CONCERNE_ACTEUR]`, et ainsi de suite. L'ensemble du mapping est défini dans la table `PREDICATE_TO_RELATION`.

Enfin, les propriétés de données OWL (`owl:DatatypeProperty`) sont injectées comme attributs de nœuds. La table `DATA_PROPS` liste les propriétés exportées : `confidence`, `legalLayer`, `nomScientifique`, `sourceYear`, `definition`, `synonym`, entre autres.

Primitive OWL	Équivalent Neo4j	Exemple
<code>owl:NamedIndividual</code> (classe C)	Nœud avec labels issus de C	<code>ZoneEEZ -> :Zone:ZoneEEZ</code>
<code>owl:ObjectProperty</code>	Relation typée en <code>SNAKE_CASE</code>	<code>appliesInZone -> [:APPLIES_IN_ZONE]</code>
<code>owl:DatatypeProperty</code>	Attribut de nœud	<code>sourceYear -> {sourceYear: 1982}</code>
<code>skos:altLabel</code>	Nœud <code>:Synonyme</code> + relation <code>[:SYNONYME_DE]</code>	<code>"high seas" -> :Synonyme lié à HM</code>
<code>rdfs:label (fr/en)</code>	Attribut <code>{label, label_en}</code>	<code>label: "Haute Mer", label_en: "High Seas"</code>

Tableau 4.2 - Correspondance des primitives OWL vers le modèle de graphe de propriétés Neo4j

4.2.2 Gestion de la sémantique héritée

Neo4j ne supporte pas nativement l'héritage de classes ni le raisonnement OWL. Pour contourner cette limitation, deux mécanismes complémentaires ont été mis en place. D'une part, la multi-labellisation encode statiquement la hiérarchie : un nœud appartenant à ChasseCommerciale reçoit également les labels Activite et ChasseBaleine, reflétant la chaîne de subsomption. D'autre part, la matérialisation des inférences (Phase 3 du pipeline) pré-calculé les relations logiquement déductibles de l'ontologie, en particulier les labels :ZoneInterdite et :ActiviteIllicite, ainsi que la relation [:EST_SOUMIS_A] issue de la chaîne de propriétés.

4.2.3 Gestion de la couche lexicale

La couche lexicale fait l'objet d'un traitement spécifique. Chaque skos:altLabel associé à une entité est extrait pour créer un nœud de type : Synonyme, contenant le texte alternatif comme propriété label. Ce nœud est relié à l'entité principale par une relation [:SYNONYME_DE]. Ce mécanisme permet au système RAG d'associer une requête formulée avec un terme non standard à l'entité canonique correspondante, ce qui renforce considérablement la robustesse de la recherche face à la variété terminologique des textes juridiques nationaux.

4.3 Construction et peuplement du graphe (Neo4j)

4.3.1 Architecture retenue et noyau expert

Le graphe a été construit de manière incrémentale, en partant d'un noyau expert composé des six interdictions qui constituent le cœur de cette étude. Ce noyau, peuplé par le module `populator.py`, constitue le point d'ancrage sémantique autour duquel l'ensemble des entités du domaine sont organisées. Chacune des six interdictions fédère un sous-graphe cohérent, reliant sources juridiques, zones d'application, acteurs concernés, activités réglementées et espèces protégées :

- **I001 - Chalutage de fond** : lié aux résolutions AGNU (61/105, 64/72, 66/68, 71/123) et aux zones d'Écosystèmes Marins Vulnérables (ZEV) et de Haute Mer.
- **I002 - Chasse à la baleine** : lié à la convention ICRW (1946), à la Commission Baleinière Internationale (IWC), et à quinze espèces de cétacés mysticètes et odontocètes.

- **I003 - Construction littorale** : lié à la Loi Littoral française (1986) et au Protocole GIZC de la Méditerranée (2008).
- **I004 - Extraction de sable marin** : lié à la Convention sur la Diversité Biologique (CDB, 1992) et aux zones côtières et ZEE.
- **I005 - Oiseaux marins migrateurs** : lié à la Convention CMS (Bonn, 1979) et à l'Accord ACAP (2004), couvrant albatros, pétrels et sternes.
- **I006 - Rejets d'hydrocarbures** : lié à MARPOL 73/78 et à ses six zones spéciales (Méditerranée, Baltique, Mer Noire, Mer Rouge, Golfe Persique, Antarctique).

4.3.2 Schéma de la base (labels, relations, propriétés)

La base Neo4j s'articule autour de dix types de nœuds principaux et d'une quinzaine de types de relations.

Tableau 4.3 - Labels de nœuds Neo4j et propriétés associées

Label Neo4j	Description	Propriétés clés
:Interdiction	Norme déontique prohibitive	id, label, deonticType, legalLayer, confidence
:Zone	Espace maritime réglementé	id, label, distanceNM, codeZoneIMO
:Activite	Activité maritime réglementée	id, label, typeActivite
:Acteur	Agent soumis aux normes	id, label, type
:EspeceMarine	Taxon marin protégé	id, label, nomScientifique, statutProtection
:SourceJuridique	Instrument de droit international	id, label, sourceYear, sourceReference
:ExceptionJuridique	Dérogation à une interdiction	id, label, comment
:Controle	Mécanisme de surveillance	id, label, definition
:Sanction	Conséquence de la violation	id, label, definition
:ConceptLexical	Terme du glossaire SKOS	id, label, definition, nomScientifique

Tableau 4.4 - Types de relations Neo4j et leur sémantique

Type de relation	Source -> Cible	Sémantique
------------------	-----------------	------------

[APPLIES_IN_ZONE]	Interdiction -> Zone	Portée géographique de la norme
[CONCERNE_ACTIVITE]	Interdiction -> Activite	Activité réglementée
[CONCERNE_ACTEUR]	Interdiction -> Acteur	Acteur destinataire de la norme
[PROTEGE_ESPECE]	Interdiction -> EspeceMarine	Espèce visée par la protection
[FONDEE_SUR]	Interdiction -> SourceJuridique	Base juridique de la norme
[A_EXCEPTION]	Interdiction -> ExceptionJuridique	Dérogation applicable
[ENTRAINE_SANCTION]	Interdiction -> Sanction	Conséquence de la violation
[EST_SOUMIS_A]	Acteur -> Interdiction	Obligation (inférence matérialisée)
[HAS_CONCEPT]	Interdiction -> ConceptLexical	Terme du glossaire associé
[SYNONYME_DE]	Synonyme -> Nœud	Pont lexical pour la recherche

4.3.3 Contraintes et indexation

Pour garantir l'intégrité du graphe, une contrainte d'unicité est définie sur la propriété id pour chaque label principal. Ces contraintes sont générées automatiquement lors de l'export :

```
CREATE CONSTRAINT IF NOT EXISTS FOR (n:Interdiction) REQUIRE n.id IS UNIQUE;
```

```
CREATE CONSTRAINT IF NOT EXISTS FOR (n:Zone) REQUIRE n.id IS UNIQUE;
```

```
CREATE CONSTRAINT IF NOT EXISTS FOR (n:EspeceMarine) REQUIRE n.id IS UNIQUE;
```

Un index fulltext nommé maritimeSearch est créé sur les propriétés textuelles des nœuds les plus interrogés, pour permettre une recherche rapide par mots-clés :

```
CREATE FULLTEXT INDEX maritimeSearch IF NOT EXISTS
FOR (n:Interdiction|Zone|Activite|Acteur|EspeceMarine|ConceptLexical)
ON EACH [n.label, n.label_en, n.definition, n.nomScientifique];
```

4.5 Analyse structurelle du graphe

Une fois le graphe construit, son analyse structurelle permet de comprendre comment le droit de l'environnement marin international s'y organise topologiquement. Cette analyse s'appuie sur des métriques de centralité, une détection de communautés et l'exploration des chemins entre catégories d'entités.

4.5.1 Centralité et nœuds structurellement dominants

Les six nœuds d'interdiction (I001 à I006) constituent les hubs à plus haute centralité de degré du graphe. Chacun concentre un nombre élevé de relations sortantes vers les zones, activités, acteurs et sources juridiques. Cette position centrale reflète bien leur rôle de pivot normatif : toute l'organisation du droit de l'environnement marin gravite autour de ces normes prohibitives.

Les nœuds de sources juridiques (UNCLOS, MARPOL, ICRW, CDB, CMS) occupent quant à eux une position de forte centralité d'intermédiarité. Ils constituent les ponts obligatoires entre les interdictions déontiques et les acteurs institutionnels qui en assurent la mise en œuvre (IMO, IWC, FAO). Cette position confère aux conventions internationales un rôle d'ancrage stable : toute modification d'une convention se propage directement à l'ensemble des normes qui y sont fondées.

4.5.2 Communautés de concepts et cohérence thématique

L'analyse des communautés confirme que le graphe se structure en six clusters thématiques correspondant aux six interdictions. Ces clusters ne sont pas totalement isolés : des nœuds partagés, comme la zone de Haute Mer (HM) ou l'entité « États Souverains », créent des ponts inter-communautés qui traduisent la transversalité de certains principes du droit de l'environnement marin.

Le cluster le plus dense se forme autour de I002 (Chasse à la Baleine), qui fédère quinze espèces de cétacés, quatre types d'acteurs (navires-usines, bateaux chasseurs, membres IWC, communautés autochtones), deux permissions distinctes (chasse scientifique et chasse de subsistance), et quatre zones de protection. Cette densité reflète la complexité juridique exceptionnelle du régime institué par l'ICRW.

On note également que les nœuds d'exception et de conséquence forment un sous-graphe transversal intéressant : chaque exception est connectée à sa conséquence normative conditionnelle, formant des chaînes logiques de type « si... alors... » qui encodent la logique conditionnelle du droit.

4.5.3 Chemins de raisonnement et inférences exploitables

L'un des intérêts principaux du graphe de connaissances est sa capacité à supporter des chemins de raisonnement multi-sauts. À partir d'un navire pétrolier, il est possible de remonter en trois arêtes à l'ensemble des zones où ses rejets sont interdits, aux sanctions applicables, et aux mécanismes de contrôle correspondants.

Concrètement, une question comme « Quelles sanctions s'appliquent à un navire pétrolier en Méditerranée ? » se traduit en une traversée de graphe de trois niveaux, résolue en temps réel sans aucune reformulation manuelle.

L'analyse révèle enfin que la chaîne [:FONDEE_SUR] vers [:MODIFIE_SOURCE] permet de tracer la généalogie juridique des normes : MARPOL 73/78 est liée à la résolution MEPC.117(52) qui l'amende, elle-même reliée aux interdictions I006. Cette modélisation diachronique des sources constitue une originalité notable par rapport aux bases de données juridiques traditionnelles.

4.6 Limites de la modélisation

L'audit du graphe a mis en lumière plusieurs limites structurelles et méthodologiques. Ces limites délimitent précisément le périmètre dans lequel le graphe peut être exploité avec confiance, et orientent les améliorations à envisager.

4.6.1 Le problème des nœuds flottants

Environ 400 nœuds ont été identifiés comme des ConceptLexical isolés, non reliés au reste du graphe par des propriétés sémantiques. Ces nœuds flottants résultent d'un manque de typage OWL rigoureux dans les premières phases d'extraction : les entités étaient stockées comme simples étiquettes textuelles plutôt qu'instanciées comme individus d'une classe OWL précise. Sans relations, ces nœuds ne participent pas au raisonnement du graphe et restent des îlots d'information inutilisables. La Phase 2 du pipeline (typage NER) a été spécifiquement conçue pour traiter ce problème, mais son efficacité reste conditionnée à la qualité des métadonnées de catégorisation produites par les LLM.

4.6.2 Absence de raisonneur en logique de description

Neo4j ne dispose d'aucun raisonneur natif en logique de description. Intégrer des raisonneurs externes comme HermiT ou Pellet, qui permettraient de calculer automatiquement toutes les inférences déductibles de l'ontologie OWL, introduirait des coûts de calcul significatifs et des difficultés d'intégration réelles. La solution retenue de matérialisation manuelle des inférences (Phase 3) est performante mais présente un défaut important : elle oblige à anticiper à l'avance l'ensemble des règles d'inférence utiles. Toute règle non explicitement

programmée ne sera pas calculée, ce qui peut engendrer des silences dans les réponses du système.

4.6.3 Hallucinations de prédicats par les LLM

Les modèles de langage ont tendance à utiliser des prédicats génériques là où l'ontologie exige des prédicats spécifiques. Un LLM peut par exemple associer une espèce marine à une interdiction via le prédicat générique `concerneActivite`, alors que la T-Box impose l'utilisation de `protegeEspece` pour ce type de relation. Ces hallucinations de prédicats produisent des triplets syntaxiquement valides mais sémantiquement faux. Le pipeline inclut une table de correction (`PREDICATE_MAP`) et un mécanisme de forçage du prédicat correct en fonction de la catégorie de l'objet, mais ces règles ne couvrent pas tous les cas possibles. Une couche de validation sémantique s'appuyant directement sur les contraintes de domaine et de portée de l'ontologie constituerait ici une amélioration substantielle.

4.6.4 Complexité de la modélisation temporelle

La gestion des périodes temporelles (OWL-Time) reste la limite la plus difficile à surmonter dans la version actuelle. L'ontologie utilise des nœuds blancs RDF (BNodes) pour représenter les instants de début et de fin des intervalles temporels, conformément à la spécification OWL-Time. Or, lors de la conversion vers Neo4j, ces BNodes sont traduits en nœuds ordinaires, ce qui complique considérablement les comparaisons de dates en Cypher. Répondre à une question comme « quelles normes étaient en vigueur entre 1990 et 2000 ? » implique de traverser deux niveaux de nœuds intermédiaires avant d'accéder aux valeurs de date. Une modélisation alternative, qui inlinerait les dates directement comme propriétés des nœuds `Periode`, permettrait des requêtes temporelles nettement plus efficaces, au prix d'une perte de conformité avec le standard OWL-Time. Ce compromis n'a pas encore été tranché et fera l'objet d'une réflexion approfondie dans une version future du système.

Ces quatre limites ne remettent pas en cause la validité globale de l'approche. Elles dessinent en revanche clairement les contours de ce que le graphe peut faire avec fiabilité aujourd'hui, et pointent vers les axes d'amélioration les plus prioritaires.

Chapitre 5 : Architecture RAG Neuro-Symbolique

Ce chapitre présente l'architecture complète du système de Retrieval-Augmented Generation (RAG) développé pour l'analyse du droit de l'environnement marin. Le pipeline est décrit de bout en bout, depuis l'ingestion des documents PDF jusqu'à la génération de réponses

juridiquement fondées, en passant par le couplage neuro-symbolique entre recherche vectorielle et raisonnement sur graphe de connaissances.

5.1 Motivation de l'approche hybride

5.1.1 Limites du RAG vectoriel seul

Un système RAG purement vectoriel, fondé sur la similarité cosinus entre la question de l'utilisateur et les passages du corpus, présente trois défaillances critiques sur un corpus de droit varié.

Le premier problème est celui du vocabulaire contrôlé : une question portant sur les « cétacés » ne retrouve pas les passages parlant de « baleines » ou de « rorquals », car les embeddings de ces termes spécialisés sont souvent éloignés dans l'espace vectoriel. La similarité sémantique des modèles généralistes échoue face à la terminologie juridique technique.

Le deuxième problème est l'absence de raisonnement multi-sauts : une question comme « Quelles sanctions s'appliquent à un navire pétrolier en Méditerranée ? » nécessite de traverser trois relations (Acteur -> Interdiction -> Zone -> Sanction). Un retriever vectoriel ne peut que retrouver des passages contenant les mots de la question, sans naviguer dans la structure normative.

Le troisième problème est la confusion des juridictions : le corpus contient des textes de 16 pays différents portant sur les mêmes thématiques. Un retriever vectoriel peut retourner un article sénégalais pour une question sur le Maroc, car le contenu textuel est sémantiquement proche.

5.1.2 Limites du LLM seul

Un LLM sans retrieval souffre de deux problèmes rédhibitoires pour un usage en droit de l'environnement marin.

D'abord, les hallucinations juridiques : le modèle peut inventer des articles de loi, des numéros de convention ou des sanctions inexistantes, ce qui est inacceptable dans un contexte d'analyse juridique.

Ensuite, l'absence de traçabilité : sans source documentaire, il est impossible de vérifier la réponse du modèle, ce qui la rend inutilisable pour un juriste.

5.1.3 Justification de l'hybridation neuro-symbolique

L'architecture proposée combine trois voies de retrieval complémentaires. Le retrieval dense (sémantique) capture le sens global des passages via des embeddings BGE-M3. Le retrieval sparse (lexical) garantit la correspondance exacte des termes juridiques via BM25. Le

retrieval par graphe (structurel) exploite les relations ontologiques pour résoudre les synonymes, expander les activités et naviguer dans la structure normative.

Ces trois voies sont fusionnées par un algorithme de Reciprocal Rank Fusion (RRF) pondéré, puis reclassées par un Cross-Encoder, avant d'être enrichies par un agent ontologique qui annote les correspondances partielles pour guider le LLM.

5.2 Architecture globale du système

5.2.1 Vue d'ensemble en couches

L'architecture se décompose en six couches fonctionnelles.

La **couche d'ingestion** (rag/ingestion/) prend en charge l'extraction du texte brut depuis les PDFs, le nettoyage, la détection de structure légale et le chunking adaptatif.

La **couche d'indexation** (rag/ingestion/embeddings_pipeline.py) assure une double indexation simultanée dans ChromaDB (dense) et BM25 (sparse).

La **couche de retrieval hybride** (rag/core/) mobilise trois retrievers indépendants (Dense, Sparse, Graph) interrogés en parallèle.

La **couche de fusion et re-ranking** (rag/core/fusion.py) applique l'algorithme RRF pondéré, suivi d'un Cross-Encoder et d'un boost ontologique par synonymes.

La **couche neuro-symbolique** (rag/neo4j_ontology_agent.py) constitue l'agent de raisonnement qui enrichit les résultats avec les faits du graphe Neo4j, les synonymes, et les annotations de correspondances partielles.

La **couche de génération** (rag/llm_generator.py) construit le prompt structuré et génère la réponse via Mistral (Ollama) ou Llama 3 70B (Groq).

5.2.2 Flux de données

Le flux de traitement d'une requête suit le parcours suivant :

Question utilisateur

|

▼

QueryAnalyzer → (intent, weights, country_filter)


|

| → DenseRetriever (ChromaDB / BGE-M3) → top-k sémantiques

| → SparseRetriever (BM25) → top-k lexicaux

| → Neo4jGraphRetriever (Cypher) → top-k structurels

|



5.3 Pipeline d'ingestion et de prétraitement

5.3.1 Extraction du texte brut

L'extraction est assurée par le module `pdf_extractor.py`, qui utilise la bibliothèque PyMuPDF (`fitz`) pour traiter les documents PDF du corpus. Ce corpus est organisé en six catégories thématiques (Baleine, Oiseaux marins, Rejet hydrocarbure, Chalutage de fond, Construction, Sable), chacune contenant les textes législatifs des 16 pays étudiés.

Pour chaque page de chaque PDF, deux opérations sont effectuées. Le texte est extrait via `page.get_text("text")`, méthode retenue pour sa robustesse dans la préservation de l'ordre des articles juridiques. Les tableaux sont détectés via `page.find_tables()` et convertis automatiquement en format Markdown pour préserver leur structure tabulaire lors de l'injection dans le prompt LLM.

5.3.2 Nettoyage non-destructif

Le nettoyage applique des règles spécifiquement conçues pour les textes juridiques : suppression des en-têtes et pieds de page récurrents (Journal Officiel, numéros de page), recollage des césures de fin de ligne (« ap-\nplication » -> « application »), fusion des lignes qui prolongent une phrase tout en préservant les doubles sauts de ligne qui constituent de vrais séparateurs d'alinéas, et corrections OCR courantes pour les textes juridiques (ex : « !' » -> « l' »).

5.3.3 Segmentation adaptative (chunking)

La segmentation constitue une étape critique pour la qualité du retrieval. Le système implémente une stratégie de chunking par unité légale, organisée en deux niveaux.

Au **niveau 1**, le découpage est structurel : le texte est segmenté sur les marqueurs de structure légale détectés par expression régulière (Titre, Chapitre, Section, Article, Règle, Annexe). Chaque unité légale constitue un chunk autonome. Ce découpage garantit qu'un chunk ne chevauche jamais deux articles différents, préservant ainsi l'intégrité juridique de chaque passage.

Au **niveau 2**, un sous-découpage par alinéa est appliqué si une unité légale dépasse la taille maximale configurée (800 tokens), avec un chevauchement (overlap) de 100 tokens pour garantir la continuité contextuelle.

Chaque chunk produit porte un breadcrumb hiérarchique (ex : [Mor] Loi n°11-03 | Chapitre III | Article 15) qui encode sa position exacte dans l'arbre du document. Ce breadcrumb n'est pas indexé dans le vector store, mais il est injecté dans le prompt LLM pour permettre la citation précise.

Un score de qualité est calculé pour chaque chunk, basé sur la présence de termes normatifs (interdit, obligatoire, sanction, amende, peine) et la longueur minimale. Les chunks dont le score est inférieur à 0.5 sont exclus de l'indexation. Une déduplication cross-catégories par hash MD5 élimine les passages identiques apparaissant dans plusieurs catégories thématiques, évitant ainsi la redondance dans l'index.

5.4 Représentations vectorielles (Embeddings)

5.4.1 Choix du modèle d'embedding

Le modèle retenu est BGE-M3 (BAAI/bge-m3), un modèle multilingue produisant des vecteurs de dimension 1024. Ce choix est justifié par trois critères. D'abord, le multilinguisme, ensuite la dimension élevée : les 1024 dimensions permettent une granularité sémantique fine, essentielle pour distinguer des concepts juridiques proches (ex : « interdiction » vs «

restriction »). Enfin, la performance sur les benchmarks : BGE-M3 figure parmi les meilleurs modèles sur le benchmark MTEB pour la recherche de similarité en français.

5.4.2 Contextual Embedding

Une stratégie de contextual embedding est appliquée lors de l'indexation : le breadcrumb hiérarchique est concaténé au texte avant l'encodage vectoriel. Le vecteur encode ainsi à la fois le contenu sémantique du passage et sa provenance légale (pays, document, article). Cette technique améliore significativement la précision du retrieval pour les requêtes filtrées par pays.

Le texte envoyé au modèle d'embedding suit le format suivant :

[Mor] Loi n°11-03 | Chapitre III | Article 15

Art. 15 - Il est interdit de rejeter en mer des hydrocarbures...

5.5 Indexation vectorielle

5.5.1 ChromaDB comme vector store

ChromaDB est utilisé en mode persistant avec la métrique de distance cosinus (HNSW). Il a été préféré à FAISS pour plusieurs raisons : une persistance native (les embeddings sont sauvegardés sur disque et rechargés automatiquement au redémarrage, sans sérialisation manuelle), des métadonnées filtrables (pays, catégorie, articles stockés directement avec chaque vecteur) et une API Python simple d'intégration.

Les métadonnées stockées pour chaque chunk comprennent : source, doc_title, category, country, page, titre, chapitre, section, article, annexe, word_count et quality_score.

5.5.2 Index BM25

Parallèlement, un index BM25 (BM25Okapi) est construit sur le texte pur (sans breadcrumb) de chaque chunk. La tokenisation utilise une expression régulière adaptée au français, qui conserve les apostrophes et les tirets ([a-zà-ÿ0-9]+(?:['-][a-zà-ÿ0-9]+)*). L'index est sérialisé via pickle pour permettre un rechargement rapide.

5.5.3 Pipeline d'indexation hybride

Le module embeddings_pipeline.py orchestre l'indexation simultanée dans les deux retrievers. Il applique un filtre de qualité (score ≥ 0.5) et une déduplication par content_hash avant indexation. L'indexation dans ChromaDB est incrémentale : les chunks déjà présents sont ignorés, ce qui permet de relancer le pipeline sans duplication.

5.6 Retrieval hybride (vectoriel + graphe)

5.6.1 Analyse de la requête

Le module `query_analyzer.py` analyse chaque requête pour en extraire trois paramètres. L'intention d'abord : neuf types sont détectés par correspondance de patterns regex (existence, sanction_penale, sanction_financiere, condition_temporelle, condition_spatiale, controle_institution, factual, legal, exploratory). Les poids des retrievers ensuite : chaque intention est associée à un jeu de poids prédéfini. Par exemple, une question de type « existence » utilise les poids (dense : 0.3, sparse : 0.3, graph : 0.4), privilégiant le graphe, tandis qu'une question de type « sanction_penale » utilise (dense : 0.2, sparse : 0.5, graph : 0.3), privilégiant la recherche lexicale exacte. Le filtre pays enfin : un code pays est extrait automatiquement de la requête par correspondance regex sur 16 pays (ex : « au Maroc » -> mor).

Tableau 5.1 - Poids des retrievers par type d'intention

Intention	Dense	Sparse	Graph
default	0.4	0.4	0.2
existence	0.3	0.3	0.4
sanction_penale	0.2	0.5	0.3
sanction_financiere	0.2	0.5	0.3
condition_temporelle	0.3	0.5	0.2
condition_spatiale	0.3	0.4	0.3
controle_institution	0.2	0.5	0.3
factual	0.2	0.3	0.5
legal	0.3	0.4	0.3

5.6.2 DenseRetriever - Recherche sémantique

Le DenseRetriever encode la requête avec le même modèle BGE-M3, puis interroge ChromaDB par similarité cosinus pour retourner les top-k passages les plus proches sémantiquement. Le score retourné est calculé comme $1 - \text{distance_cosinus}$.

5.6.3 SparseRetriever - Recherche lexicale

Le SparseRetriever tokenise la requête avec la même regex française, puis calcule les scores BM25 sur l'ensemble du corpus. Les résultats sont triés par score décroissant, et seuls les passages avec un score strictement positif sont retournés.

5.6.4 Neo4jGraphRetriever - Recherche structurelle

Le Neo4jGraphRetriever constitue l'apport original de l'architecture. Il implémente une stratégie de retrieval en trois branches.

La première branche est la résolution d'espèces : si la requête contient un terme déclencheur d'espèce (baleine, cétacé, tortue, etc.), Neo4j est interrogé pour retrouver toutes les interdictions qui protègent cette espèce, avec les synonymes, les conventions applicables et les zones de protection.

La deuxième branche est l'expansion d'activités : si la requête contient un terme d'activité (chasse, pêche, extraction, etc.), les sous-activités spécifiques connues par l'ontologie et les interdictions associées sont retrouvées.

La troisième branche est le contexte générique : pour les autres termes, une recherche fulltext est effectuée dans Neo4j et les relations du nœud trouvé sont agrégées.

Les résultats du graphe sont formatés en texte synthétique structuré (ex : « Espèce : Baleine bleue. Aussi appelé(e) : rorqual bleu, Balaenoptera musculus. Protégé(e) par les interdictions : I002. Conventions applicables : ICRW. ») pour être compatibles avec le pipeline de fusion.

5.6.5 Stratégie de fusion - Reciprocal Rank Fusion

La fusion des trois retrievers est assurée par l'algorithme RRF pondéré, implémenté dans fusion.py. Pour chaque document d retrouvé par un retriever r à la position rank_r , le score RRF est calculé comme :

$$\text{Score_RRF}(d) = \sum_r (\text{weight}_r / (k + \text{rank}_r))$$

où $k = 60$ (constante de lissage standard). Les poids weight_r sont déterminés par le QueryAnalyzer en fonction de l'intention détectée.

Un boost ontologique multi-synonymes est ensuite appliqué : pour chaque document, si son texte contient l'un des synonymes résolus par Neo4j, un bonus de 0.05 est ajouté à son score RRF. Ce boost est plafonné à 1.5x le score maximal pour éviter l'explosion.

Un filtrage strict par pays est appliqué aux résultats des retrievers dense et sparse : seuls les documents dont le champ country correspond au filtre pays détecté dans la requête sont conservés. Les résultats du graphe sont exemptés de ce filtre, car ils contiennent des faits internationaux applicables à tous les pays.

5.6.6 Re-ranking par Cross-Encoder

Après la fusion RRF, les 30 meilleurs candidats sont soumis à un Cross-Encoder (cross-encoder/ms-marco-MiniLM-L-6-v2) qui recalcule un score de pertinence sémantique profonde en évaluant conjointement la paire (question, passage). Les 5 meilleurs passages après re-ranking constituent le contexte final transmis au LLM.

5.7 Couplage neuro-symbolique

5.7.1 Agent de raisonnement ontologique

Le module `neo4j_ontology_agent.py` constitue le cœur du couplage neuro-symbolique. Il implémente un workflow en sept étapes.

Étape 1 - Détection des entités : Les termes d'espèce et d'activité sont identifiés dans la requête par correspondance avec des dictionnaires de mots-clés. Les références juridiques (Convention, Résolution, MARPOL, UNCLOS) sont détectées par expressions régulières.

Étape 2 - Résolution des synonymes : Pour chaque entité détectée, Neo4j est interrogé pour récupérer l'ensemble de ses synonymes SKOS. Ces synonymes sont transmis au LLM pour qu'il sache que « cétaqué » = « baleine » = « rorqual ».

Étape 3 - Faits directs et multi-sauts : Les faits directs sont les relations à un saut du nœud (ex : I002 -> protège -> Baleine bleue). Les faits multi-sauts traversent la chaîne de protection : Espèce -> Interdiction -> Convention -> Zone.

Étape 4 - Expansion des activités : Les termes génériques (« chasse ») sont expansés vers leurs spécialisations connues par l'ontologie (« chasse à la baleine », « chasse aux dauphins »).

Étape 5 - Enrichissement croisé PDF -> graphe : Les entités nommées extraites des chunks PDF (références juridiques, espèces) sont recherchées dans Neo4j pour compléter le contexte avec des faits supplémentaires.

Étape 6 - Détection des correspondances partielles : C'est la fonctionnalité la plus originale du système. Quand un chunk PDF parle de « chasse » en général mais que la question porte sur « chasse à la baleine », l'agent génère une annotation de correspondance partielle qui informe le LLM de cette nuance. Cela évite les réponses OUI/NON trop catégoriques lorsque le texte ne confirme que partiellement la question.

Étape 7 - Construction de l'EnrichedContext : Toutes les informations collectées sont assemblées dans une structure de données EnrichedContext qui sera injectée dans le prompt.

5.7.2 Construction et injection du prompt LLM

Le PromptBuilder assemble le prompt final en trois blocs ordonnés.

Le premier bloc est ontologique (référentiel international) : synonymes résolus, faits juridiques internationaux, expansions d'activités, annotations de correspondances partielles.

Le deuxième bloc est documentaire (textes nationaux) : les passages PDF re-rankés, avec leur breadcrumb (chemin exact dans le document).

Le troisième bloc contient la question de l'utilisateur suivie d'une instruction spécifique à l'intention détectée.

Le system prompt impose au LLM un protocole strict : écrire une analyse préliminaire entre balises <analyse> et </analyse> avant de répondre, commencer la réponse par « OUI » ou « NON », ne répondre OUI que si le texte contient explicitement la notion demandée, citer obligatoirement la source, le chemin exact et l'article verbatim, et ne jamais mentionner les termes techniques du système (ontologie, Neo4j, prompt).

Des instructions spécifiques sont définies pour chaque type d'intention. Par exemple, pour l'intention `sanction_penale`, l'instruction précise : « Si le document mentionne UNIQUEMENT une sanction financière (amende) mais AUCUNE peine de prison, tu DOIS répondre NON à la question sur la prison, puis préciser qu'il existe une amende financière. »

5.7.3 Détection et correction des hallucinations

Le mécanisme anti-hallucination repose sur trois niveaux.

Le premier est le Chain-of-Thought forcé : le LLM doit expliciter son raisonnement dans la balise <analyse>, ce qui réduit les raccourcis logiques et les syllogismes erronés.

Le deuxième est la distinction explicite/déduit : le system prompt interdit formellement les déductions logiques. Si le texte dit « espèces protégées » sans mentionner « interdiction de chasse », le LLM doit répondre NON à une question sur l'interdiction de chasse.

Le troisième est la gestion des annotations partielles : les correspondances partielles détectées par l'agent ontologique préviennent le LLM qu'un terme générique trouvé dans le texte ne confirme pas l'activité spécifique demandée

5.8 Génération des réponses (LLM guidé)

5.8.1 Modèles LLM utilisés

Le système supporte deux backends de génération. Le premier est Ollama (local), avec le modèle Mistral 7B exécuté localement. Cette option est adaptée au développement et aux tests, mais reste lente pour le traitement de volumes importants de questions (30 à 60 secondes par question). Le second est Groq (cloud), avec le modèle Llama 3.3 70B Versatile exécuté sur l'infrastructure Groq, qui offre des temps de réponse de l'ordre de 2 à 5 secondes par question et convient mieux au traitement en production.

Le basculement entre les deux backends est automatique : si la variable d'environnement `GROQ_API_KEY` est définie, le système utilise Groq ; sinon, il se rabat sur Ollama.

5.8.2 Paramètres de génération

La température est fixée à 0 (quasi-déterministe, pour maximiser la fidélité aux sources). Le nombre maximum de tokens est de 1024 (suffisant pour une réponse structurée avec citation). Le timeout est de 300 secondes pour Ollama, et illimité pour Groq.

5.9 Synthèse et discussion de l'architecture

5.9.1 Tableau comparatif

Tableau 5.2 - Comparaison des architectures RAG

Critère	RAG vectoriel classique	GraphRAG standard	Architecture proposée
Retrieval	Cosinus seul	Graphe seul	Dense + Sparse + Graphe
Résolution de synonymes	Non	Partielle	Dynamique via SKOS/Neo4j
Raisonnement multi-sauts	Non	Oui	Oui (matérialisé)
Filtrage par pays	Métadonnées	Non	Strict (dense/sparse) + exempt (graph)
Détection d'ambiguïté	Non	Non	Correspondances partielles
Anti-hallucination	Non	Non	CoT forcé + annotations
Re-ranking	Non	Non	Cross-Encoder
Traçabilité	Source seule	Nœud graphe	Source + chemin hiérarchique + verbatim

5.9.2 Analyse des compromis

Sur le plan de la performance, l'ajout du graphe et de l'agent ontologique augmente la latence d'environ 500 ms par requête (résolution de synonymes, expansion d'activités, détection de correspondances partielles). Ce surcoût est marginal face au temps de génération LLM (2 à 60 secondes selon le backend), mais il devient significatif à l'échelle d'un traitement portant sur 1056 questions.

Sur le plan de l'explicabilité, le protocole Chain-of-Thought et les citations verbatim obligatoires rendent chaque réponse vérifiable par un expert humain, au prix d'une réponse plus longue et plus coûteuse en tokens.

Sur le plan de l'adaptabilité, les poids des retrievers sont définis statiquement par type d'intention. Une approche apprise (learned fusion) pourrait améliorer les performances, mais nécessiterait un jeu de données d'évaluation annoté qui n'est pas disponible pour le domaine du droit de l'environnement marin.

5.9.3 Robustesse du système

Le système intègre un mécanisme de graceful degradation via le module `neo4j_bridge_safe.py` : en cas de panne de Neo4j, le retriever graphe et l'agent ontologique sont désactivés automatiquement, et le système continue à fonctionner avec le seul retriever dense et sparse. Un health check dans l'interface Streamlit affiche en temps réel l'état de chaque composant (Dense, Sparse, Graph, LLM, Neo4j).

Références bibliographiques du chapitre